

青 山 学 院 大 学
理 工 学 研 究 科

理工学専攻 知能情報 コース

修 士 論 文

学 生 番 号 35623242

氏 名 平井 龍彦

研究指導教員 ロペズ・ギヨーム 教授

Graduate School of Science and Engineering, Aoyama Gakuin University

Title: IMU-Based Automatic Evaluation Method for Soccer Shooting Form

Student Name: Tatsuhiko Hirai

ID Number: 35623242

Degree: Master of Engineering

Course: Intelligence and Information

Thesis Advisor: Professor Guillaume Lopez

Abstract

With advancements in information technology, the application of technology in soccer has progressed, leading to the development of various support systems. However, most of these systems focus on performance analysis rather than providing detailed assistance for skill improvement, such as shoot form enhancement.

This study aims to develop a skill improvement support system that players can use independently using an affordable Inertial Measurement Unit (IMU) sensor. Specifically, it compares and evaluates two methods for automatically assessing soccer shooting form: motion recognition and evaluation using sensor-based posture estimation and form evaluation using machine learning.

IMU sensors are attached to both ankles and the chest in the proposed method to collect acceleration and angular velocity data. The posture estimation approach applies a complementary filter to estimate the sensor's orientation. The player's posture is calculated from the sensor's posture estimation results. Meanwhile, the machine learning approach detects and segments shooting motions from time-series data and extracts features to construct a classification model. The evaluation accuracy of both methods is compared across four assessment criteria.

The results show that the machine learning approach accurately distinguishes good and poor shooting forms, while the posture estimation method effectively recognizes key shooting phases and analyzes form characteristics. However, some errors were observed in posture estimation. Overall, the machine learning method demonstrates superior accuracy, while the posture estimation approach proves helpful for motion segmentation and analysis.

Future work should focus on expanding data collection to include a more diverse range of players to improve model generalization. Although the posture estimation method had lower evaluation accuracy, its effectiveness in motion segmentation and analysis was demonstrated. Improving its precision through algorithm refinement and optimizing sensor placement could enhance its applicability for form evaluation.

理工学専攻修士論文要旨

提出年度： 2024 年度

提出日： 2025 年 1 月 31 日

専修コース： 知能情報 コース

学生番号： 35623242

学生氏名： 平井 龍彦

研究指導教員： ロペズ・ギヨーム 教授

(論文題目)

慣性計測装置を用いたサッカーにおけるシュートフォーム自動評価手法

(内容の要旨)

近年の IT 技術の進化により、サッカーにおける技術活用が進んでいる。プロサッカーでは、選手のパフォーマンス分析が重視され、カメラベースのシステムによる戦術解析やウェアラブルセンサによる選手のパフォーマンス分析やコンディション管理に利用されている。アマチュア向けのサポートシステムも登場し、手軽にフィジカルデータの取得が可能となった。しかし、これらは主にパフォーマンス分析を中心であり、キックフォームの改善など細かいスキル向上を支援する機能は限られている。このため、より詳細な技能向上を目的としたシステムの開発が求められている。

本研究では、安価な小型慣性計測装置 (IMU) を用いて、選手自身で利用可能な技能向上支援システムの開発を目的としている。具体的に、サッカーのシュートフォームを自動評価する手法として、IMU のデータから姿勢を推定し、シュート動作の認識及び評価の精度を検証する。さらに、比較検証として、先行研究でサッカー動作の識別や熟練度の判定に活用されていた機械学習を用い、シュートフォームの良否判定の精度を検証する。これにより、姿勢推定と機械学習の両手法の有効性を評価し、より適切なフォーム評価手法を明らかにすることを目標とした。

提案手法では、IMU センサを選手の両足首および胸部に装着し、加速度・角速度データを取得する。姿勢推定手法では、取得したデータに対して適切な前処理を施した上で、相補フィルタを用いてセンサの姿勢を推定する。その後、推定した姿勢情報を基に、シュートの主要なポイントであるアプローチ、バックスイング、インパクト、フォロースルーの動作を認識し、選手のフォームを推定する。機械学習手法では、IMU センサの時系列データからシュート動作の自動検出およびセグメントを行い、加速度・角速度の 6 軸の統計データを抽出する。これらの特徴量を用いて機械学習モデルを構築し、シュートフォームの良否を識別する。本研究で扱うフォームの評価項目には、バックスイング時の蹴り足の角度、フォロースルー時の蹴り足の角度、軸足の傾き、上半身の傾きの 4 つの項目を設定し、それぞれの手法の評価精度を比較する。バックスイング時の蹴り足の角度、フォロースルー時の蹴り足の角度は、角度の推定値としてそれぞれ算出し、ラベリング結果との平均絶対誤差 (MAE) および平均絶対誤差率 (MAPE) を算出する。そのほかの評価項目は推定結果とラベリング結果の一一致率を算出し、評価精度を検証した。

結果として、姿勢推定手法と機械学習手法による評価精度を比較したところ、機械学習手法がより高精度にフォームの良否を識別できることが確認された。時系列データから特徴を抽出し、適切な分類モデルを用いることで、フォームの良否を高い精度で判定できた。姿勢推定手法では、相補フィルタを用いた姿勢推定により、シュートの主要なポイントを認識し、フォームの特徴を解析したが、一部の姿勢推定に誤差が見られた。総合的に、機械学習手法は精度面で優れており、姿勢推定手法は動作の分割と解析に有用であることが明らかになった。

本研究では、現役の選手を対象にデータの収集実験を行ったため、フォームの良し悪しに偏りが生じる可能性があった。今後は、より多様な選手を対象にデータを収集し、モデルの汎用性を向上させる必要がある。また、姿勢推定手法は評価精度としては低かったものの、動作の分割と解析に有用であることが示された。精度の向上により、フォーム評価にも有効な手法となる可能性があるため、アルゴリズムの改良やセンサ配置の最適化を進めすることが求められる。

慣性計測装置を用いたサッカーにおける シュートフォーム自動評価手法

平井 龍彦

2025/1/31

目次

第1章 序章	3
1.1 現代サッカーにおける研究背景	3
1.1.1 サッカーの競技者数と指導者の関係	3
1.1.2 サッカーのIT技術の活用	5
1.1.3 ウェアラブルサッカーサポート製品	6
1.2 研究目的と目標	7
1.3 本論文の構成	8
第2章 関連研究	9
2.1 複数のサッカー動作を識別した研究	9
2.2 熟練者と未熟練者の違いを解析および識別した研究	12
2.3 サッカー動作の評価に関する研究	14
2.4 選手・コーチへのサポートシステムを開発した研究	16
2.5 先行研究で残された課題と本研究の優位性	18
第3章 サッカースキルの向上支援の提案手法	20
3.1 サッカースキル向上支援の概要	20
3.1.1 本研究で扱うサッカー動作	20
3.1.2 正しいキックフォームの定義	21
3.1.3 本研究で扱う評価項目	22
3.2 計測システムの開発	23
3.2.1 計測システムの開発	23
3.2.2 センサの装着位置	24
3.3 姿勢推定による動作評価手法	24
3.3.1 姿勢推定による動作評価手法の概要	24
3.3.2 センサの姿勢推定処理	25
3.3.3 シュート動作の主要ポイントの認識	29
3.3.4 姿勢推定手法によるシュートフォーム評価	31
3.4 機械学習による動作評価手法	32
3.4.1 機械学習による動作評価手法の概要	32
3.4.2 セグメンテーション手法	33
3.4.3 特徴量の抽出	34
3.4.4 機械学習手法によるシュートフォーム評価	34

第4章 提案手法の検証実験	36
4.1 データ収集実験	36
4.1.1 実験目的	36
4.1.2 被験者	36
4.1.3 実験方法	36
4.1.4 データ収集実験の結果	37
4.2 ラベリング方法	38
4.3 評価精度検証方法	39
4.3.1 姿勢推定手法の検証方法	39
4.3.2 機械学習手法の検証方法	40
第5章 提案手法の検証結果と考察	41
5.1 姿勢推定による動作評価手法の結果と考察	41
5.1.1 姿勢推定による動作評価手法の結果	41
5.1.2 姿勢推定による動作評価手法の考察	42
5.2 機械学習による動作評価手法の結果と考察	42
5.2.1 機械学習による動作評価手法の結果	42
5.2.2 機械学習による動作評価手法の考察	44
第6章 結論と今後の展望	46
6.1 結論	46
6.2 今後の展望	46
謝辞	48
参考文献	49

第1章 序章

1.1 現代サッカーにおける研究背景

1.1.1 サッカーの競技者数と指導者の関係

サッカーは世界的に人気であるスポーツの1つで、世界中に35億人以上を超えるファンがいると言われている [1]. 特にワールドカップなどの国際大会では、世界中のサッカーファンが注目し、スポーツ文化の一環として大きな影響力を持っている。日本のサッカー競技人口に着目すると、2023年度の日本サッカー協会の登録者数は約83万人である [2]. 図1.1は1979年から2023年までの日本サッカー協会の登録者数の推移を表している。1993年のJリーグ開幕をきっかけに競技者数が増加し、近年は増加と減少を繰り返しているながらも、概ね80万人以上の競技者数を維持している。このような競技者数の推移はJリーグやワールドカップなどが大きく影響し、今後もサッカーが日本国内の主要なスポーツとなると考えられる。図1.2は2023年度の登録選手の各カテゴリーの割合を表している。Jリーグに所属するプロサッカー選手は全体で0.2%で、ほとんどがアマチュア以下の選手であることがわかる。特に若年層が大半を占めており、これは部活動や地域のクラブなど、サッカーを行う機会が多いことが大きな要因として挙げられる。このように若年層の競技者数が多いことは日本サッカーの将来にとって重要であり、これを維持するには教育的な側面や地域の格差への配慮が必要である。

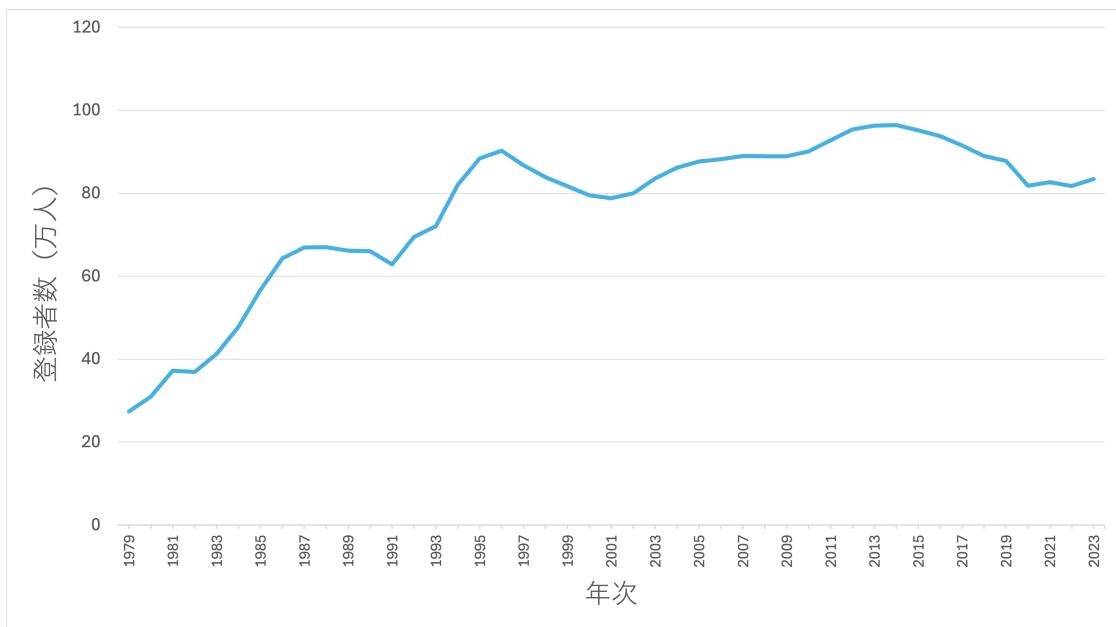


図 1.1: 日本サッカー協会 選手登録数 (1979年～2023年) ([2]より引用)

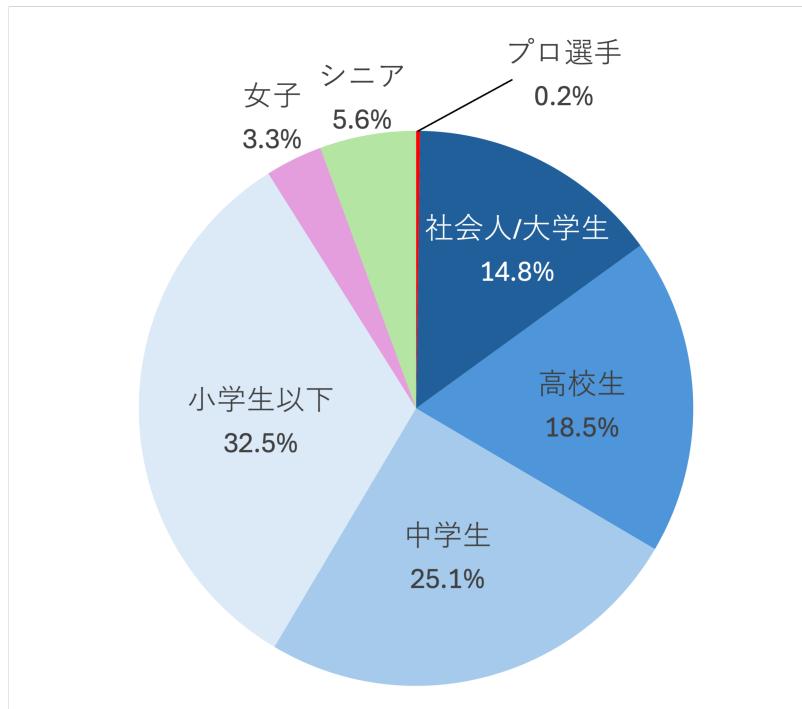


図 1.2: 日本サッカー協会 カテゴリー別選手登録割合（2023 年度）([2] より引用)

図 1.3 は日本サッカー協会に登録されている指導者数の推移を示しており、継続的に増加し、2023 年度には9万人を超えており ([3]。日本サッカー協会では、指導者に対して、指導レベルに応じたライセンスを発行しており、プロフェッショナルレベルの S 級コーチから、アマチュアレベルの A～D 級コーチに分類されている [4]。特に、アマチュアレベルの中でも A 級と B 級は「質の高いサッカー指導が可能である」とされる指導者に与えられるライセンスであるが、A 級は全体のわずか3%，B 級は9%に過ぎず、これらのライセンス保持者の割合は非常に少ない。

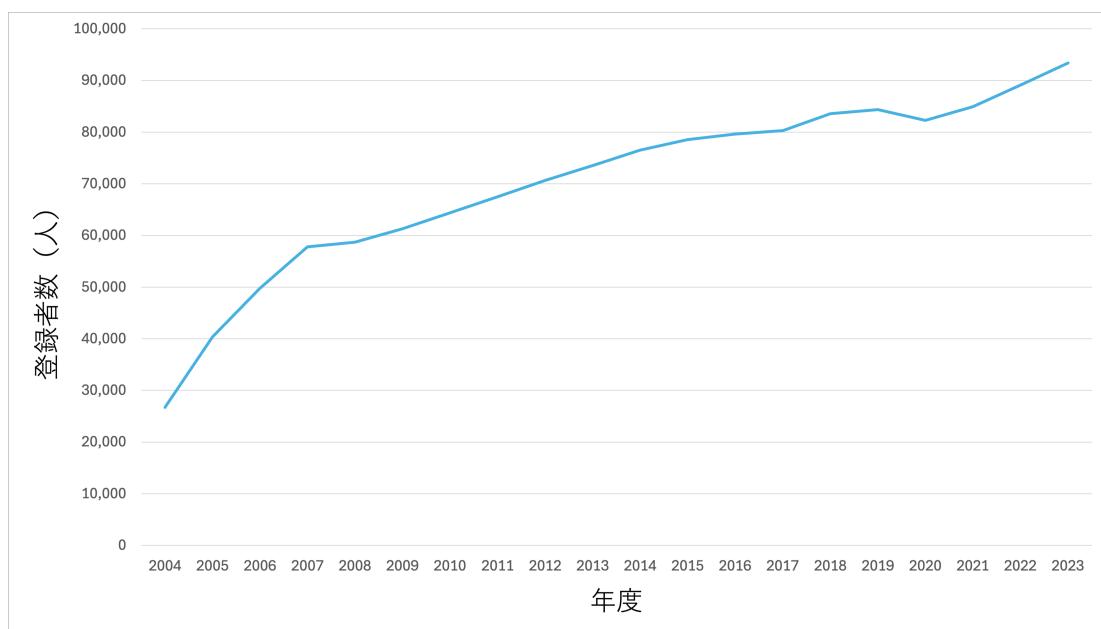


図 1.3: 日本サッカー協会 指導者数（2004 年～2023 年）([3] より引用)

日本サッカー協会の指導者登録数は増加傾向にあるものの、選手一人当たりの指導者数は依然として不足しており、これは選手一人に与える指導の質に直接的な影響を及ぼしている。選手と指導者の適切な比率は年齢層によって異なるが、一般的に年齢が若いほどより多くの指導者が必要と考えられている。イングランドのサッカー連盟（The FA）は、コーチと選手の適切な比率についてガイドラインを出しており、コーチ1人あたりに対する選手数として、4～8歳は6人、9～12歳は8人、13～18歳は10人を推奨している[5]。これは年齢が低く、技術的に成長の初期段階において質の高い指導が非常に重要であり、年齢が上がるにつれて熟練度及び自立度が高くなるため、指導者数がより少ない人数でも効率的に指導できるようになるからである。ただし、年齢が上がった場合でも、指導者の不足は、選手一人当たりに十分な指導が行き届かず、技術の習得や戦術理解が十分に進まないというリスクとなることは同様である。このため、指導者数および指導の質の向上が日本サッカーの将来にとって重要な課題となる。

1.1.2 サッカーのIT技術の活用

現代のIT技術の進化に伴い、その技術がサッカーに対して活用されることが増えた。プロサッカーの試合では、試合を円滑かつフェアに進めるために、審判をサポートするためを利用される事例が多く見られる。代表的なものとして、2012年に競技規則に導入された「ゴールライン・テクノロジー（GLT）」がある[6]。GLTはボールがゴールラインを完全に超えたかどうかを判断するために使用される技術であり、重要な得点シーンでの誤審を防ぐことが可能である。ゴールラインの両側に設置されたカメラやセンサがボールの位置を正確に測定することで、得点があったかどうかを審判に通知する仕組みである。さらに、2018年からは「ビデオ・アシスタント・レフェリー（VAR）」システムが正式に導入された[6]。VARは主審が見逃した可能性のある重大なプレーについて、ビデオ映像を確認することで判定をサポートするシステムである。特にゴール、ペナルティキック、レッドカードなど試合の行方に大きく影響する場合で使用される。VARの導入により、試合の公平性を高めることができた。

また、選手やコーチなどの競技者をサポートするため、IT技術が活用されることも増えている。チームのマネジメントおよびパフォーマンスのモニタリングを目的として、ドイツの大手ソフトウェア企業SAPによって開発された「SAP Sports One」（図1.4）がある[7]。このシステムはサッカーをはじめとするプロスポーツチームに向けて設計されており、チーム運営のさまざまな側面でサポートすることができる。ウェアラブルデバイスや高精細カメラによってフィールド上の選手とボールの動きをトラッキングし、走行距離やスプリント速度、パス成功率などをリアルタイムに解析する。選手に対するサポートとして、各選手のスマートデバイスで確認することを可能にすることで、自身のパフォーマンスを客観的に振り返ることができる。一方でコーチに対するサポートは選手の位置や相手チームの情報をもとに戦術の最適化を図ることができる。同時に医療データや生体データから選手のコンディション管理をすることで怪我の予防や早期発見に貢献する。これによってチームは試合に向けた準備を効果的に進めることができる。「SAP Sports One」はドイツのFCバイエルン・ミュンヘンや、日本のヴィッセル神戸など世界19ヶ国で80チーム以上をサポートしている。

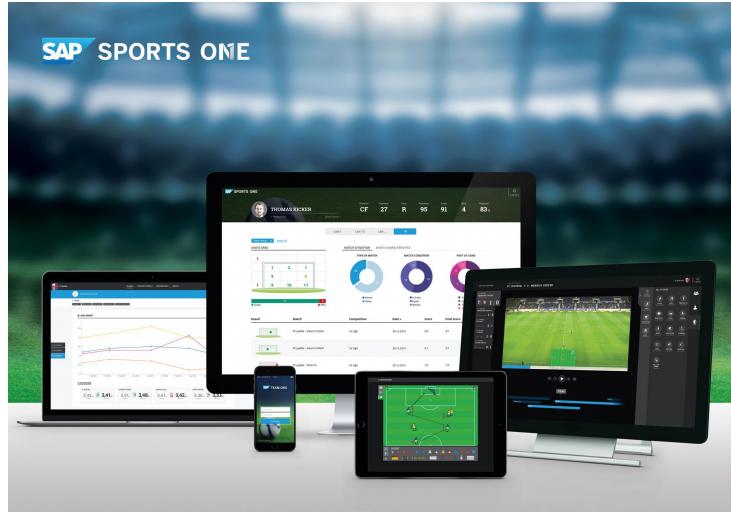


図 1.4: SAP 社が開発した SAP Sports One ([7] より引用)

1.1.3 ウェアラブルサッカーサポート製品

サッカーのパフォーマンス分析には、映像解析によるカメラベースと信号解析によるセンサベースの2種類が主流である。カメラを用いたシステムは選手全体やフィールドの広範囲を捉えることができ、戦術的な分析には優れているが、設置や運用に高いコストと手間がかかるというデメリットがある。一方、ウェアラブルデバイスは比較的容易に導入することが可能であり、個々の選手の動きをリアルタイムにトラッキングすることで、個人のパフォーマンス向上に役に立つデータの取得ができる。市販されているウェアラブルなサッカーサポートデバイスはプロ向けの高価なものからアマチュア向けの安価なものまである。

Catapult 社の「Catapult Vector Pro」(図 1.5) は世界中の 1200 以上のプロサッカーチームで利用されている GPS を用いた代表的なサポートシステムである [8]。このデバイスを背中に装着することで、走行距離、走行速度、加速・減速、脈拍数などの情報を計測することができる。高精度なトラッキングにより、個人のパフォーマンスの定量化やチーム全体の戦術改善、怪我のリスク低減が可能である。これらのデバイスは個人向けではなくチーム全体のサポートに特化したシステムである。



図 1.5: Catapult 社が開発した Vector Pro ([8] より引用)

一方で、比較的安価で個人向けなシステムとして、Playermaker 社が開発した「Playermaker 2.0」(図 1.6) がある [9]. このシステムはスパイクに取り付けるタイプのスマートセンサを用いたアマチュア向けのウェアラブルシステムである。内蔵された加速度センサと角速度センサから取得したデータから、走行距離やスプリント数、各足のタッチ数やパス数、キックパワーなどの情報をトラッキングすることができる。

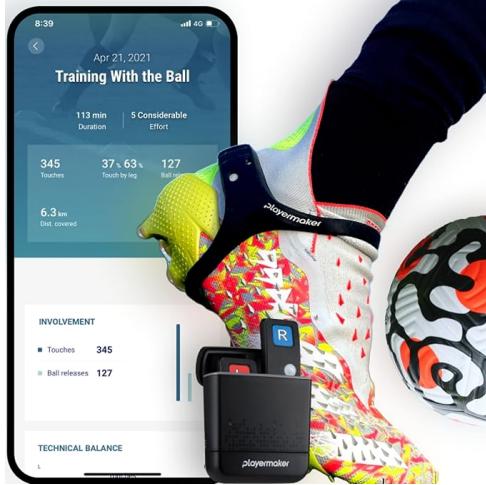


図 1.6: Playermaker 社が開発した playermaker2.0([9] より引用)

ウェアラブルデバイスは選手個々の動きをリアルタイムにトラッキングし、パフォーマンスを詳細に評価できる点で優れており、装着するだけで簡単に利用できるという特徴がある。しかし、取得できるデータや評価指標には限りがあるため、キックフォームの細かい改善を提示するような機能はないという課題がある。他にも様々なサッカーサポート製品があるが、選手のレベルや目的に応じた情報の取得ができるものを選び、有効に活用することで、自身のパフォーマンス向上に繋げることが可能である。

1.2 研究目的と目標

1.1.1 項で述べたように、サッカーは世界中で人気であり、日本においてもJリーグの開幕などをきっかけに競技者が増加し、その大半は若年層を占める。しかし、選手一人あたりの指導者数は十分であるとは言えず、指導者全体の指導の質に関しても改善の必要性が課題として挙げられている。

1.1.2 項で述べたように、現代のIT技術の進化に伴い、それらの技術をプロサッカーの試合やチーム運営に活用されていることがわかった。審判へのサポートでは試合を円滑に進めるために、競技者へのサポートではパフォーマンスの評価や怪我の予測に役立てられている。これらの技術はプロチームに向けた高価なものであり、アマチュアにとっては導入は難しいという課題がある。

一方で、1.1.3 項で述べたように、ウェアラブルなサポート製品が多く販売されており、アマチュア向けの比較的安価な製品もある。これらの製品は選手の動きをトラッキングし、パフォーマンスを評価でき、装着するだけで簡単に利用できるという特徴がある。しかし取得できるデータの限界からキックフォームの細かい改善を提示するような機能はないという課題が残されている。以上のことから、本研究の目的は安価な小型の慣性計測装

置を用いて、指導者がいない環境においても選手自身で利用可能なキックフォームフィードバックシステムを開発することとする。

以下に本研究の目的を達成するための目標を示す。

- サッカー動作の重要な評価基準の設定
- サッカースキルの自動評価手法の検証

1.3 本論文の構成

本論文は以下の構成である。

第1章：本論文の研究背景、研究目的及び論文の構成について述べる。

第2章：サッカーの技術支援を目的とした先行研究と本研究の位置付けについて述べる。

第3章：提案するシュートフォームの自動評価手法について述べる。

第4章：検証に用いるデータ収集実験と提案手法の精度検証について述べる。

第5章：精度検証の結果および考察を述べる。

第6章：本論文の結論と今後の展望について述べる。

第2章 関連研究

2.1 複数のサッカー動作を識別した研究

サッカーは、パス、シュート、ドリブル、ヘディングなど多様な動作から成り立つスポーツである。これらを正確に識別することは、選手の特性理解や戦術改善、そして技能向上システムの実現において重要である。この分野では、選手の動作を計測する手法として、センサ技術や映像解析技術が活用されている。本節では、それぞれの手法を用いたサッカー動作の識別に関する研究を紹介する。

青柳らは、右足に装着した小型な慣性計測センサを用いて、サッカーの基本動作であるシュート、ドリブル、パス、ヘディングを識別する手法を提案した[10]。慣性計測センサから収集した3軸加速度データからサッカー動作を検出し、自動セグメンテーションによって分割した。さらに分割した動作データから特徴量を抽出し、ランダムフォレスト、サポートベクターマシン、ロジスティック回帰、k近傍法、ガウスナイーブベイズ分類器の5種類の分類モデルで動作の識別精度を検証した。その結果、シュート、パス、ドリブルは90%以上の精度で検出が可能であり、特にサポートベクターマシンでは85%以上の分類精度を達成した。一方で、ヘディングの検出と分類精度が低く、ヘディングの識別精度の改善が課題として残った。

D.Schuldhauseらは、IMUセンサベースの計測システムを利用し、シュートとパスを識別する手法を提案した[11]。図2.1に示すように、スパイクの内部にIMUセンサ、脛当てに記憶装置を設置し、両足の加速度と角速度を計測するシステムを開発した。取得したデータから信号振幅ベクトル(SMV)を算出し、ピーク検出によって動作をセグメントした。セグメントした部分から平均、分散、歪度、尖度の4つの統計的特徴を抽出し、サポートベクターマシン、分類回帰木、ナイーブベイズの3種類の分類モデルによって分類精度を検証した。分類は2段階で分類する階層的アプローチを採用し、まずイベント(シュート、パス)とその他(タックル、ランニング、サイドステップを含む)に分類し、次にイベントからシュートとパスに分類した。結果として、イベントとその他の分類精度は89.5%，シュートとパスの分類精度は84.2%を達成し、サポートベクターマシンが最も高い性能を示した。



図 2.1: (左) スパイク内部の IMU センサ, (右) 脛当ての記憶装置 ([11] から引用)

伊藤らはサッカー選手のオフザボールに着目した動作分析システムを提案した [12]. このシステムは地磁気センサ, 角速度センサ, GPS センサを選手の体に装着し, それらのデータを組み合わせることで, 選手の向き, 動作内容, 位置情報を分析する. 図 2.2 にセンサおよび周辺機器の装着位置を示す. 大腿部に装着した角速度センサで内転・外転や屈曲・伸展による角速度変化を測定し, 歩行, 走行, ステップワーク, ジャンプなどの動作を判別することを可能にした. また, 背中に装着した地磁気センサで選手の向いている方向を判別し, GPS センサを用いて選手の位置情報を取得する仕組みを構築した. 基礎評価によってマルチセンサの組み合わせで詳細な動作分析が可能であることが確認された. しかし精度検証は行われておらず, 試合での実用性を考慮したセンサ装着方法や GPS センサの位置測定の精度向上が課題として残された.

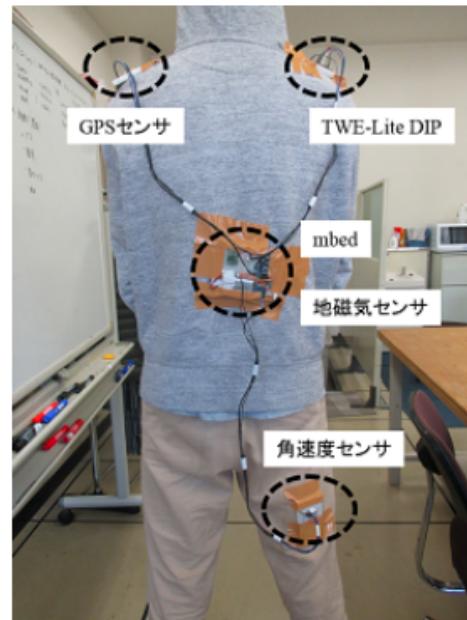


図 2.2: センサおよび周辺機器の装着位置 ([12] から引用)

Stoeve らはシューズに装着した IMU センサで計測したシュートとパスを深層学習モデルによって識別する手法を提案した[13]。データ収集には、制御された条件下での環境と実際の試合や練習の環境で行い、それぞれの環境下での識別精度を検証することでシステムの有効性を検証した。分類モデルは、先行研究のサポートベクターマシンと 3 つの深層学習モデル(CNN, LSTM, convLSTM) を採用した。スライディングウィンドウ法による自動セグメンテーションを行い、加速度と角速度の各軸のキックフェーズ中の信号の絶対和を計算し、6 つの特徴量を分類器に入力した。結果として、試合や練習の環境で収集されたデータにおいて CNN が F1 スコア 92.8% の最も高い識別精度を示した。

Mascher らは、MEMS 加速度センサを搭載したスマート脛当てを開発し、サッカー選手の動作識別を目的とした性能評価を実施した[14]。本システムでは立つ、歩く、走る、パス、シュートの 5 つの動作を対象とし、3 軸加速度データから合成加速度のピークを検出してセグメンテーションを実施した。特徴量抽出に主成分分析と線形判別分析を適用し、機械学習アルゴリズムとしてロジスティック回帰、サポートベクターマシン、ランダムフォレスト、人工ニューラルネットワークの分類精度を比較した。分類は 2 段階で行い、第一段階でキックと他の動作、第二段階で詳細に分類するというアーキテクチャを提案した。結果として、線形判別分析を適用したロジスティック回帰とランダムフォレストが最も高い精度を達成した。被験者数が 1 人に限定されており、さらなるデータ収集やドリブルなどの複雑な動作を含む分析が課題として残された。

Alobaid らは加速度センサを搭載したスマートフォンを腹部に装着し、サッカーの 5 つの基本動作(シュート、パス、ヘディング、ランニング、ドリブル)をリアルタイムに識別する手法を提案した[15]。分類手法は、Time Series Forest Classifier (TSF), Fast Shapelet Transform Classifier (FS), Bag of SFA Symbols (BOSS)，これらの複数のアルゴリズムの長所を組み合わせた協調モデルの 4 つを比較した。結果として、協調モデルの精度が最も高い精度(84%)を達成し、学習時間を短縮することも可能であった。一方で、腹部にスマートフォンを装着する方法は激しい動作が行われるサッカーには不向きであり、カメラを元に 3 秒間のウィンドウでセグメントしているため動作外のデータが含まれてしまう点が課題として残された。

Hossain らは、リストバンド型のウェアラブルデバイスを用いて、サッカー選手の動作を解析するシステム「SoccerMate」を開発した[16]。このシステムはパス、キック、スプリント、ランニング、ドリブルなどの動作を分類し、パフォーマンスを数値化することを目的としている。解析には、加速度データを用いて、動作の変化点を検出し、イベントごとにデータを分割し、Restricted Boltzmann Machine を用いた深層学習による動作の分類を行った。全体の分類精度は 86.5% に達し、「走行」や「ランニング」、「静止」の動作においては高い精度を示した。一方で、ドリブルの動作は速度変化が明確にデータに現れない場合が多く、精度が低下することが確認された。

今井らは、カメラで取得したサッカートラッキングデータを用いて、選手とボールの位置情報から 10 種類のボールタッチプレーを自動認識する手法を提案した[17]。データは J1 リーグ公式 20 試合分を使用し、ボールの軌道や速度の変化に基づく条件でプレーを検出した。認識には Conditional Random Field (CRF), サポートベクターマシン、ランダムフォレストの 3 種類の機械学習モデルを比較し、ボールの移動距離や選手間の距離などを特徴量として利用した。結果として、プレーの検出は 86% を達成し、全体的に高い性能

を示した。一方で、プレーの認識はプレーごとに精度に差が見られ、パスやトラップは高い精度を示したがシュートやクリアなどの一部のプレーでは精度が低下する傾向が見られた。データ数が少ない動作や曖昧な動作の認識に課題が残された。

2.2 熟練者と未熟練者の違いを解析および識別した研究

サッカーの熟練者と未熟練者の動作にはそれぞれ特徴的な差が存在する。それを解析することで、技能向上のための指標を提供することが可能となる。この分野では、サッカー動作のデータ収集手法として、センサ技術や映像解析技術が活用されている。本節では、熟練度の違いに着目したサッカー動作の解析に関する研究を紹介する。

紅林らは、スポーツの動作解析を目的とした計測システムを開発し、現役サッカー選手と未経験者のインステップキック動作の違いを明らかにした[18]。計測システムはArduino、3軸加速度センサ・角速度センサ、モバイルバッテリーを組み合わせて構築されており、足に装着することでキック動作を計測することができる。現役のサッカー選手と未経験者を対象とした実験の結果、現役選手はキック前に足を大きく引き上げ、加速度と角速度の最大値が高く、効率的な動作を行っていることが確認された。一方、未経験者は足の動きに無駄が多く、キック後も不要な動作が見られるなど、動作の非効率性が明らかになった。今後の課題として、上半身の動作にも着目し、サッカーの熟練度による違いを詳細に分析すること、本格的な利用に向けた計測デバイスの小型化などが挙げられた。

真鍋らは、身体7箇所に装着した慣性センサから取得したデータを基に、サッカー経験を持つ上級者と初心者のインステップキック動作を解析し、その違いを明らかにした[19]。静止したボールと動いたボールの両方を対象にキック動作の実験を実施し、解析では特に骨盤と蹴り足に注目した。解析の結果、上級者は初心者に比べて、骨盤の前後および上下方向の回転速度が速く、蹴り足の角速度も高いことが確認された。特に、動いているボールに対するキックでは、これらの違いが顕著に増加し、効率的に伝達していることが示された。また、スキルテストによるインステップキックのスコアと蹴り足の回転速度には正の相関が見られ、競技者の技術レベルを動作データを基に定量化できることを明らかにした。

Piechotaらは、熟練度が異なるサッカーのゴールキーパーを対象に、筋電図(EMG)を用いて意思決定時間と筋電図緊張値の違いを解析した[20]。2対1の典型的なゲーム状況を模擬し、シュートが打たれてからゴールキーパーがセーブアクションを完了するまでを意思決定時間と定義し、図2.3に示すように、両足の10箇所に装着された筋電図でデータを収集した。結果として、熟練者は未熟練者より意思決定時間が優位に短いことが確認された。また、熟練者は主要な姿勢筋の動作範囲を最適化し、効率の良い動作パターンを示した。一方、未熟練者は筋電図の緊張値が高く動作効率が低い傾向が示された。これらの結果から、熟練者が視覚情報と筋肉活動の連携を通じて動作の精度と効率を向上させていることが示唆された。

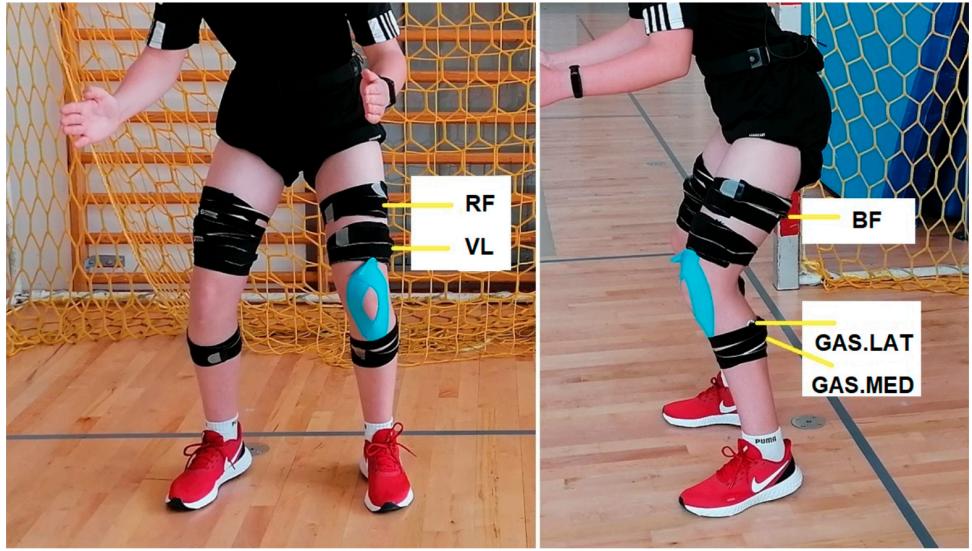


図 2.3: 筋電図の装着位置 ([20] から引用)

Ross らは、モーションキャプチャデータを用いて生成したIMUセンサのシミュレーションデータを活用し、エリート選手と初心者を識別する分類手法を提案した[21]。モーションキャプチャから得た動作データを基に、IMUデータとして線形加速度と角速度をシミュレーションし、7種類の動作の分類を行った。検証では、モーションキャプチャを用いた分類精度とシミュレートされたIMUセンサを用いた分類精度で比較された。結果として、モーションキャプチャの分類精度は平均78.1%に対して、シミュレートされたIMUデータでは平均80.2%を記録し、IMUデータがモーションキャプチャと同等以上の精度を示すことが確認された。結果より、比較的低成本なIMUセンサでも動作の評価が可能であることが明らかになった。

中村らは、熟練者と未熟練者のインステップキック動作を解析し、その違いを明らかにした[22]。測定には図2.4に示したモーションキャプチャ測定システムを用いて実施された。解析ではボールの速度、腰部や股関節の動き、軸足の傾斜角度に着目した。結果として、熟練者はボール速度が速く、腰部の動きが大きいことから体幹を効率的に活用してエネルギーを伝達していることが示された。また、股関節では屈曲や外旋の動作範囲が広く、正確で力強いキック動作が可能であることが明らかになった。さらに、軸足の傾斜角度が大きいことで安定した姿勢を保ちながらキックを行っている点が特徴として挙げられた。一方、未熟練者はこれらの動きが全体的に小さく、動作効率が悪いことが確認された。

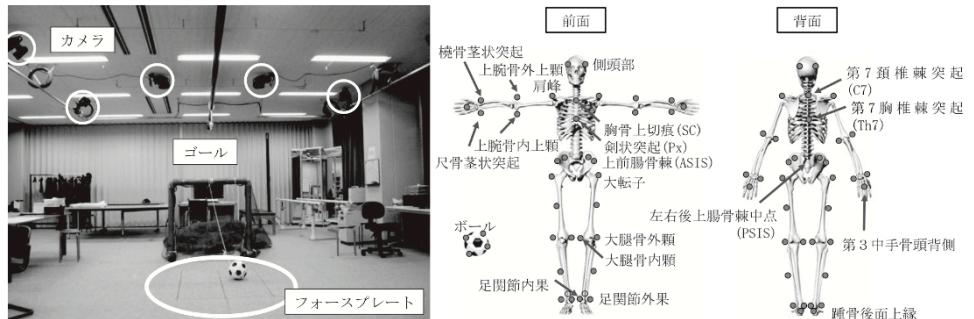


図 2.4: (左) 測定システムの全景、(右) マーカの設置位置 ([22] から引用)

辻元らは、3次元動作解析システムを構築し、サッカー未経験者と熟練者のインステップ動作の違いを分析した[23]。このシステムは被験者に反射マーカを装着した状態で、4台のハイスピードカメラで撮影し、動作分析ソフトと用いた3次元DLT法によって各部位の三次元座標を取得することができる。解析の結果、熟練者は膝関節の伸展角速度が高く、下肢のムチの動作を効率的に利用していた。一方、未経験者は股関節が過剰に屈曲し、股関節の伸展角速度が低いことなど効率的なキック動作ができていないことが示された。未経験者は軸足の傾きが小さく、インパクト時に安定した姿勢を取っていないことも明らかになった。今後の課題として、未経験者のキック技術向上を目指した指導法の開発や熟練者の動作を基にした効率的な練習法の提案が挙げられた。

金子らは、人体の関節座標を取得するツール「OpenPose」を用いて、サッカーのシュート動作を解析し、熟練度を識別する手法を提案した[24]。身体の18箇所の関節座標を取得し、体の向き、軸足の位置、腰の回転、フォロースルーの4つの特徴量を抽出した。これらの特徴量を基に、サポートベクターマシン、ランダムフォレスト、ロジスティック回帰などの機械学習モデルで、熟練度を分類した。結果として、ランダムフォレストが最も高い精度である84.0%を達成した。さらに、体の向きや腰の回転が熟練度を識別する上で重要な指標であることが示された。また、関節座標データを活用することで、体の向きや腰の回転などを数値化できる可能が確認され、動作解析における有効性が示唆された。

正木らは、モーションキャプチャ技術を活用して、サッカーのトラップおよびパス動作における経験者と未経験者の違いを解析した[25]。被験者の上半身3点（頭部、脊椎、腰部）から三角形の面積と傾き角度を特徴量として算出し、経験者と未経験者の識別に有用であるかを検証した。また、これらの特徴量を教師あり学習の分類モデル用いることで、分類精度を評価した。結果として、経験者は動作中の姿勢が安定しており、三角形の面積や傾き角度の変動が小さいことが確認された。一方で、未経験者は体軸のブレが大きく、三角形の面積と傾き角度に大きな変動が見られた。さらに提案した特徴量を用いた分類精度は、次元を削減しない生データを直接用いた分類精度に近い結果を示し、動作傾向の分析や識別に有効であることが示された。

2.3 サッカー動作の評価に関する研究

サッカー動作を定量的に評価することで、選手の現在の技術レベルを客観的に把握し、具体的な改善点を特定することにつながる。また、評価結果を基にトレーニング内容を最適化することが可能となり、効果的なスキル向上が期待できる。定量的な評価を行うモデルを開発するために、センサ技術やカメラ技術を用いて選手の動作データが収集される。本節ではこれらの技術を用いた動作評価に関する研究を紹介する。

Yuらは、足に装着したIMUセンサの軌跡を推定することによって、キック動作の質を評価する解析手法を提案した[26]。IMUセンサで収集した加速度・角速度データからクォータニオンによる姿勢推定、座標変換することによって2次元および3次元の軌跡を構築した。図2.5はインステップキック時のデータから構築された2次元および3次元の軌跡を表している。提案手法は軌跡データから蹴り足の最大速度、バックスイングの最高点を抽出することで動作の特徴を解析した。精度検証には、高速カメラで取得したビデオデータを正解データとして利用し、IMUセンサによる推定結果との比較を行った。その結果、

足の最大速度とバックスイングの最高点についてはそれぞれ誤差4%と2.8%と高い精度を達成した。軌跡の位置誤差は0.07m、速度誤差は0.034m/sと低い値を示し、IMUセンサを用いた解析がキック動作の詳細な特徴を識別する手法として有効であることが示唆された。

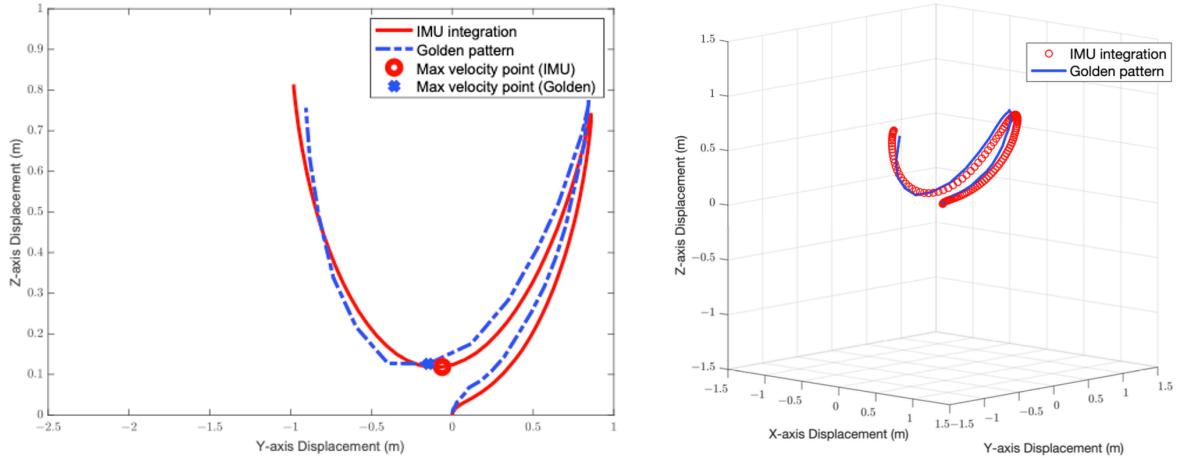


図2.5: (左) インステップ時の2次元のIMUセンサの軌跡、(右) インステップ時の3次元のIMUセンサの軌跡([26]から引用)

Wilmesらは、サッカー動作の中で加速、減速、切り返し、ジャンプ、キックに着目し、動作の強度を評価するシステムを提案した[27]。9軸IMUセンサを下半身の5箇所（骨盤、大腿部、脛部）に装着し、膝および股関節の角度と角速度を算出し、動作の強度として「低」「中」「高」の3段階で精度の検証をした。モーションキャプチャを基準とし、RMSD（ルート平均二乗誤差）を用いて角度の誤差を評価し、CMC（多重相関係数）を用いてIMUセンサとモーションキャプチャ間のデータ一致度を測定した。その結果、膝関節と股関節の角度におけるRMSDはそれぞれ平均5.3°および8.0°であり、CMCは0.985および0.940と非常に高い一致率を示した。これらの結果は、IMUセンサを用いて動作の強度を正確に評価できる可能性を示唆している。

Takizadehらは、k近傍法（KNN）アルゴリズムとIMUセンサを組み合わせて、子供のキックスキルを評価する手法を提案した[28]。IMUセンサを両足のくるぶし上部と腰部に装着し、収集した加速度および角速度データを基に、子供の運動発達を質的に評価する標準化された項目（TGMD-3）に基づいて基礎運動スキルの評価を自動化した。専門家によるスコアリングと本システムの評価結果を比較し、一致度を算出した結果、0.90と高い精度が確認された。また、システムの評価分類精度も95%に達し、動作の正確な評価が可能であることが示された。さらに、本システムは従来の手動評価と比較して、1回の動作の評価時間を平均5分から30秒未満に短縮する効率性も実証された。

Radaらは、選手評価および選抜のセレクションに有効な指標として、ポケットレーダーを用いたボール速度による評価手法を提案した[29]。ユースサッカー選手を対象に、ポケットレーダーで記録した最大キック速度を基に、年代カテゴリ（U-15, U-17, U-19）およびチームステータス（ファーストチームとリザーブチーム）の違いを統計的に分析した。また、受信者動作特性（ROC）解析を用いて、測定結果が競技レベルを区別する診

断能力を評価した。結果として、ファーストチームの選手はリザーブチームの選手より一貫して高いキック速度を示し、特に若年カテゴリ（U-15 および U-17）でその差が顕著であった。また、ROC 解析により、最大キック速度は競技レベルを区別する上で有効な指標であることが確認された。

安達らは、ビデオカメラと深層学習技術を用いて、ロングキック、トラップ動作を自動評価し改善アドバイスを提示する個人練習支援システムを提案した[30]。このシステムでは、Google MediaPipe を用いて選手の骨格情報を推定し、各関節の角度を算出した。図 2.6 は MediaPipe の骨格推定の結果例である。この結果を基に、理想のフォームから逸脱したポイントを特定し、改善に向けたアドバイスを生成する仕組みである。システムの精度検証では、モーションキャプチャシステムを基準として、一致度およびアドバイスの表示回数を比較した。経験者における一致度は 7 割に達し、未経験者では誤表示が見られたものの、全てのアドバイスを提示することができた。課題として、ビデオカメラの角度により体の一部が隠れることで、骨格推定の誤差や精度低下が生じる点が挙げられた。

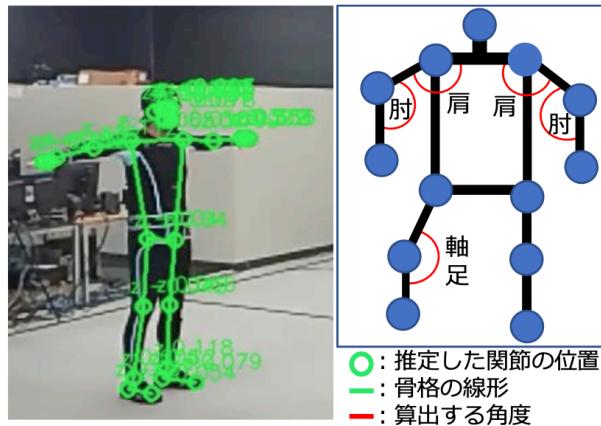


図 2.6: MediaPipe による骨格推定の結果例 ([30] から引用)

2.4 選手・コーチへのサポートシステムを開発した研究

節 2.1～2.3 節では、サッカー動作の識別や評価に関する研究について述べた。一方で、動作の識別や評価を活用し、具体的なフィードバックを通じて選手やコーチを直接的に支援するサポートシステムも開発されている。これらのシステムは、トレーニング内容の改善や戦術指導の補助に役立ち、選手のパフォーマンス向上や健康管理を支援するものである。本節では、これらのサポートシステムの概要とその効果について紹介する。

Marris らは、サッカー動作を識別するシステムを利用して、ポジションやトレーニングメニューごとの技術動作の頻度や傾向を解析した[31]。このシステムはボールタッチやりリース（パス、シュートなど）の動作を記録することが可能である。システムの識別精度の検証として、ビデオカメラを基準に比較した結果、一致率 95% という高い精度で動作を識別可能であることを明らかにした。さらに、ポジション別の解析では、中盤選手が最も多く技術動作を行い、トレーニングメニューごとの解析では、小規模ゲーム形式の練習が技術動作の頻度を最も高めることが確認された。コーチが練習メニューや戦術の改善に役立つ具体的なデータを得ることが可能であることを示した。

Ikram らは、サッカー選手の健康管理を目的とした IoT ベースの監視システム「IoT Football」(図 2.7) を開発した [32]。このシステムは、選手に装着されたセンサから生理的データ（心拍数、体温、発汗率など）をリアルタイムに収集し、クラウド上で解析することで健康状態の異常を検出する。また、気温や照明強度といった環境データも収集し、選手の健康とパフォーマンスに影響を与える要因を総合的に監視し、異常が検出された場合にはモバイルアプリを通じてコーチや監督にアラートを通知する仕組みになっている。検証実験では、健康異常の検出率が 99% 以上という高精度を示し、リアルタイム通知により迅速な対応が可能であることが確認された。モバイルアプリを通じた通知機能の正確性や遅延時間を評価した結果、異常発生時に迅速かつ正確にアラートが送信されることが実証された。

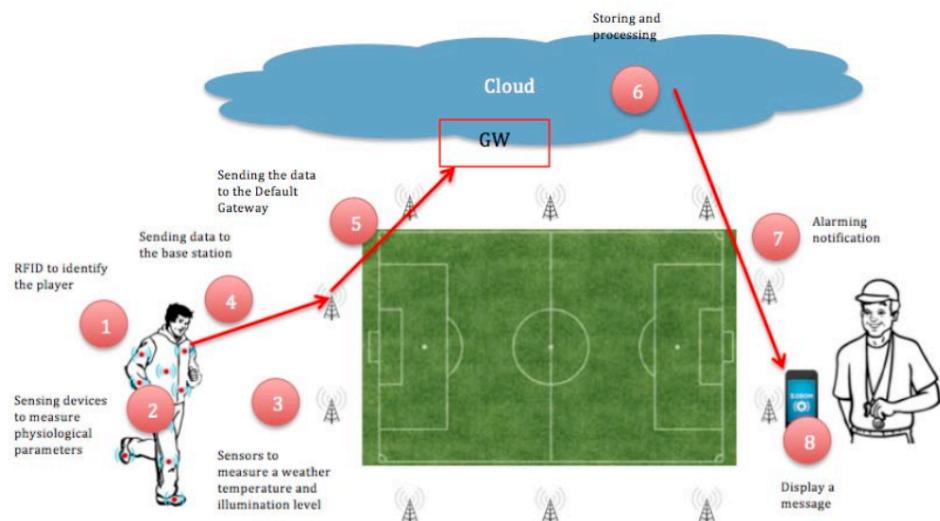


図 2.7: 「IoT Football」 のシステム構成図 ([32] から引用)

Stensland らは、選手のパフォーマンス解析と戦術可視化の効率化を目的としたリアルタイムサポートシステム「Bagadus」(図 2.8) を提案した [33]。トラッキングセンサ、カメラ、コーチ向けのアノテーションツールを統合し、選手の動きやイベントをリアルタイムで記録・解析する。複数のカメラで撮影した映像を動的に切り替えたり、選手の位置データを基に特定イベント（パスやシュートなど）を自動的にタグ付けする機能を提供する。さらに、過去のプレーデータを瞬時に検索し、特定の状況を再生することも可能である。システムの検証では、位置データと映像の同期性能やイベント抽出・再生までの時間を測定した。遅延時間は平均 671ms で、リアルタイム解析に十分な効率性を示した。本研究は、選手のパフォーマンス向上やコーチによる戦術改善を効果的に支援するシステムとして有効であることを示している。

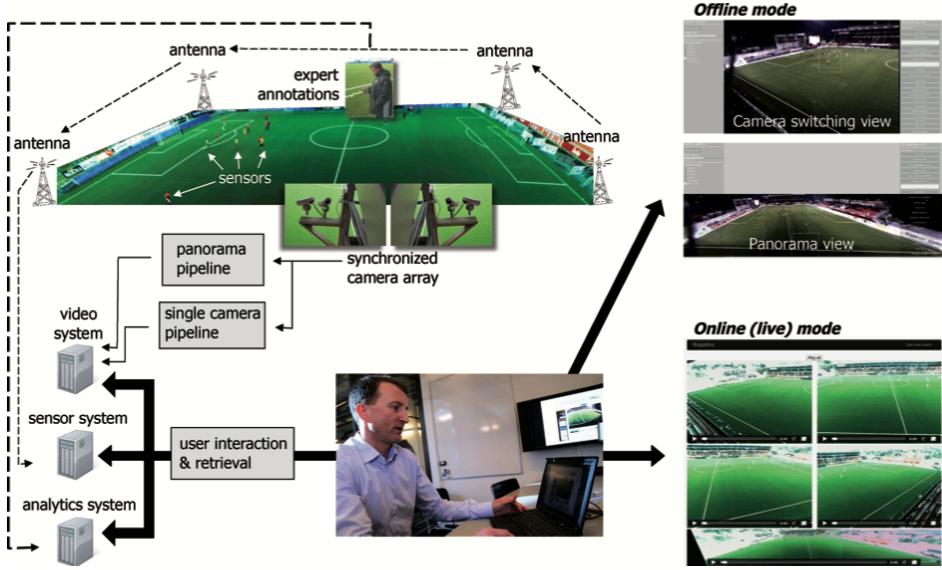


図 2.8: 「Bagadus」のシステム構成図 ([33] から引用)

2.5 先行研究で残された課題と本研究の優位性

2.1 節では、サッカー動作の識別に関する研究を紹介した。ウェアラブルセンサやカメラから取得したデータを機械学習や深層学習を用いて分類することで、シュート、パスなどの基本動作を高精度で識別できることができることが示された。しかし、ヘディングやドリブルなどの複雑な動作に関しては識別精度が低いなど、使用するセンサによってプレーの認識精度に差が見られる課題が残った。また、これらの研究では動作の識別に重点を置いており、選手個人のフォーム改善や技術向上の支援まで至っていない。2.2 節では、サッカーの技能レベルの識別や動作の違いを解析した研究を紹介した。技能レベルの識別については、機械学習を用いることで高精度な識別が可能であることが示された。また、技術レベルによる動作の違いを詳細に解析した結果、熟練者は効率的かつ無駄の少ないフォームで動作する一方、未熟練者には非効率的な動作が多いことが明らかになった。このことから、IMU センサやカメラで収集したデータに適切な信号処理や映像解析を適用することで、動作の評価を行い、具体的かつ実用的な技術向上支援システムの実現が可能であることが示唆された。2.3 節で述べた、サッカーの動作評価に関する研究では、関節角度やバックスイングの高さなどフォームの特徴の数値化や、ボール速度や動作の強度を判定することが可能であることが示された。しかし「良いフォーム」を明確に定義したものは少なく、それを基準とした総合的なフォーム評価は十分に行われていない。さらに、評価結果を選手にフィードバックする仕組みの構築がされていないという課題があった。2.4 節では、選手やコーチを支援するサポートシステムに関する研究を紹介した。これらのシステムは主に選手の健康管理や戦術改善に重点を置いており、生体データや技術動作を解析することでトレーニングを補助することができ、トレーニング内容や指導を補助することが可能となる。これらのシステムはチームの活動のサポートには有効である一方で、選手個人の技術向上を直接的に支援する仕組みは考えられていない。

以上のことから、本研究ではサッカー技能向上を目的としたサッカー動作のフォーム改善を支援するシステムを開発する。まず、選手に負担の少ない計測システムを構築すると

ともに、サッカー動作を詳細に認識する。さらに正しいフォームを明確に定義し、その定義に基づいて動作を評価判定するアルゴリズムを確立する。また、本研究ではカメラを用いる手法に比べて利用環境への負担が少なく、選手に装着するだけで計測が可能なIMUセンサを採用することで、指導者がいない環境でも選手自身が効率的にトレーニングに取り組むことができるシステムを目指す。図2.9に本研究の位置付けを示す。

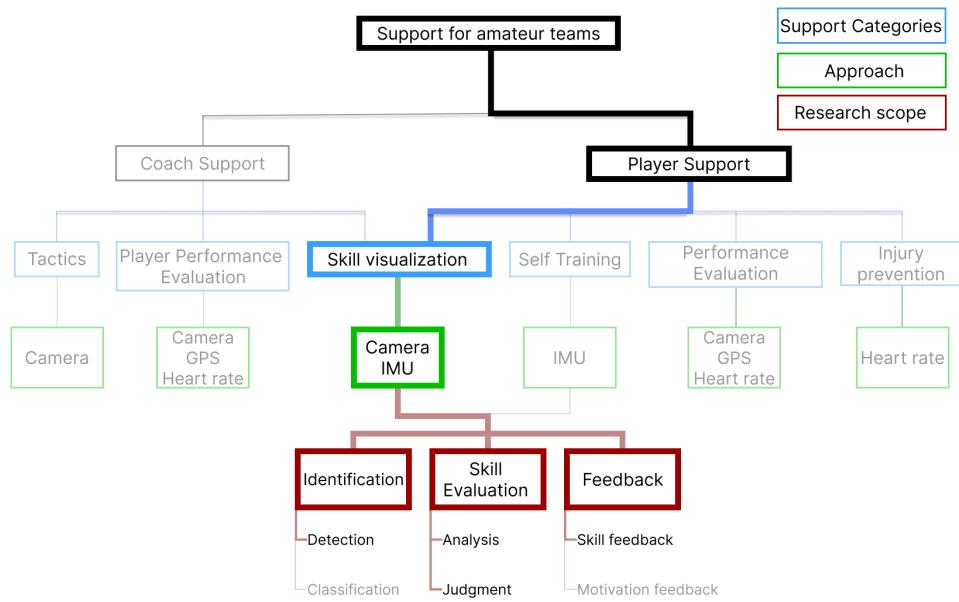


図2.9: 本研究の位置付け

第3章 サッカースキルの向上支援の提案手法

3.1 サッカースキル向上支援の概要

本節では、本研究で対象とするサッカースキル、正しいフォームの定義、定義をもとに設定した評価項目について説明する。

3.1.1 本研究で扱うサッカー動作

サッカーには多くの重要なスキルが存在し、大きく分けると「オープンスキル」と「クローズドスキル」の2種類に分類される。図3.1にサッカースキルの全体図を示す。「オープンスキル」とは、外的要因によって変化する状況に適応する能力を指し、具体例としてプレーの判断力や状況の把握能力などが挙げられる。一方、「クローズドスキル」とは、安定した環境下で決められた動作を再現する能力を指し、シュート、パス、ドリブルといった基本的なサッカースキルと呼ばれる技術がこれに該当する。サッカーのパフォーマンスを向上させるには、どちらのスキルも必要不可欠である。理想は、これらのスキルをバランスよく習得していくことが望ましいが、スキルの習得は年齢による影響を大きく受ける。JFA（日本サッカー協会）は、特に若年層においてクローズドスキルの習得を推奨している[34]。これは、U-10～U-12の年代が「ゴールデンエイジ」と呼ばれる、技術習得に最適な時期であるためである。この時期に身につけた基本技術は長期的に維持されやすい特徴がある。一方で、年齢が上がるにつれて練習内容がオープンスキル中心へ移行する傾向があり、技術の新たな習得や修正が比較的に困難になる。そのため、本研究では若年層における効率的な技術習得だけでなく、高年層の技術の習得・向上を支援することを目的として、クローズドスキルに着目する。

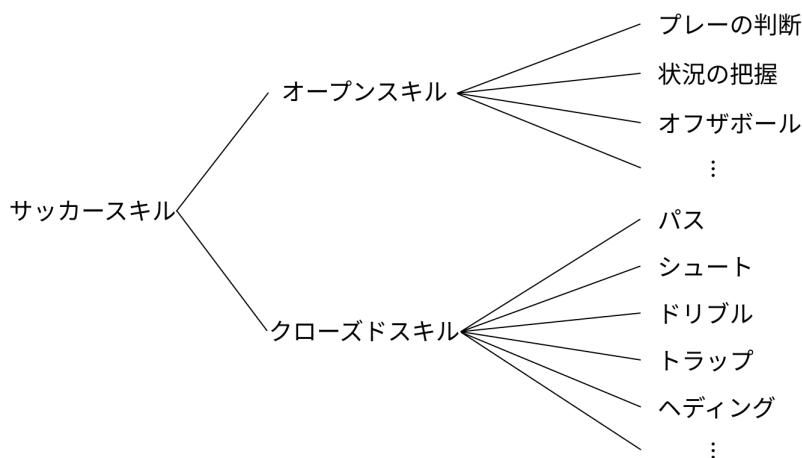


図3.1: サッカースキルの全体図

サッカーにおけるクローズドスキルは、図3.1が示すように多様なスキルが含まれる。これらのスキルは全て重要であるが、特に「シュート」が試合結果やチームの成績に大きな影響を与えることが先行研究で明らかにされている。Bilekらは、2017-2018シーズンのイングランド・プレミアリーグの試合データを分析し、試合結果および得点数に影響を与える要因を特定する研究を実施した[35]。分析の結果、枠内シュート数が多いほど得点の可能性が高まり、試合の勝率が向上する傾向が示された。また、Souzaらは、2010年から2018年のスペイン・ラ・リーガの試合データを分析し、シーズン終了時の勝ち点に影響を与える要因を調査した[36]。その結果、攻撃面ではシュート精度の高さ、守備面では相手チームのシュート機会を減らし、被シュートの精度を低下させることがチームの好成績に繋がる要因であると結論づけている。これらの研究結果からシュートが試合結果を左右する重要なスキルであることが分かる。本研究ではシュートフォームを評価する手法を提案し技能向上の支援を目指す。

3.1.2 正しいキックフォームの定義

シュートフォームを評価するために、正しいキックフォームを定義する。まず、図3.2に示すキック動作における4つの主要なポイントを明確に設定した上で、そのポイントを基準に3つのフェーズとして分割し、正しいフォームを定義する。以下にキック動作における4つの主要なポイントと本研究で各動作を識別するための基準を示す。

1. アプローチ

キックのためにボールに向かう一連の動作

識別の基準：蹴り足がインパクト前に最後に地面に設置した状態

2. バックスイング

蹴り足を後ろに引く動作

識別の基準：蹴り足が最も高い位置になった状態

3. インパクト

蹴り足をボールに接触する動作

識別の基準：蹴り足がボールに接触した状態

4. フォロースルー

蹴り足をターゲットの方向に最後まで振り切る動作

識別の基準：蹴り足が前方に伸び切った状態

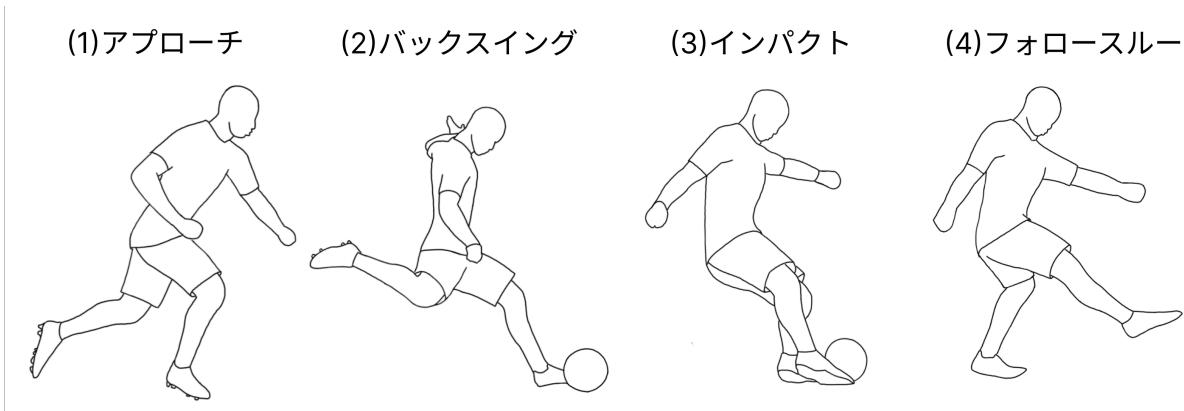


図 3.2: キック動作の 4 つの主要なポイント

これらの 4 つの主要ポイントを元にシュート動作を 3 つのフェーズに分割し、各フェーズの正しいフォームを定義する。本研究では、既存の研究論文およびサッカー技術に関する教本を参考に正しいフォームを定義した。研究論文はキック動作をバイオメカニクスの観点で解析し、効果的な動作や身体の状態に関する知見がまとめられている [37]。また教本ではキックの種類やボールの質を決める要素、それを踏まえた実践的な正しいフォームが画像付きで説明されている [38]。これらをもとに、各フェーズにおける正しいフォームを以下の通りに定義する。

バックスイングフェーズ（アプローチ～バックスイング）

- ・蹴り足：高い位置で十分に振りかぶっている
- ・軸足：ボールの真横または少し前に適切な距離で接地できている。

インパクトフェーズ（バックスイング～インパクト）

- ・蹴り足：足首が最大限に伸展し、ぶれないように固定されている
- ・インパクト位置：ボールの中心近くをインパクトできている
- ・軸足：ブレーキをかけるようにすねの角度を後ろに倒している
- ・上半身：後傾していない（前傾または直立）

フォロースルーフェーズ（インパクト～フォロースルー）

- ・蹴り足：蹴り足を止めずに上ではなく前方に足を振り抜いている
- ・上半身：ターゲットの方向を向いている

3.1.3 本研究で扱う評価項目

3.1.2 項で定義した正しいキックフォームを元に、本研究で扱うシュート動作の各フェーズの評価項目を設定した。これらの評価項目は、慣性計測装置を用いて計測可能であると判断したものを選定した。また、評価としてフォームの良し悪しを判定する方法と、具体

的な姿勢角度などを定量化する方法がある。良し悪しの基準が明確に定義されている動作については判定を行い、基準が曖昧な動作については客観的な評価が可能となる数値で表現する。

評価項目 1: バックスイング

十分に高い位置に蹴り足を運んでいるか

評価項目 2: フォロースルー

蹴り足を上ではなく、前に振り抜くことができているか

評価項目 3: 軸足の傾き

インパクト時に、ブレーキをかけるように軸足の脛の角度が後ろに倒れているか

評価項目 4: 上半身の傾き

フォロースルー時に、上半身が後ろに倒れていないか

3.2 計測システムの開発

本節は、シュート動作を計測するためのシステムについて説明する。本研究では選手の動作を計測する手段として、IMU（慣性計測装置）センサを採用する。アマチュア選手にとって、高精度なカメラシステムなどの高価なデバイスを利用することは現実的ではなく、また個人での利用を考慮した場合、カメラを用いた計測環境を構築するには多大な労力とコストがかかるという課題がある。これらの理由から本研究では、比較的安価であるIMUセンサを活用することにより、低コストかつ手軽に計測可能なシステムを構築する。

3.2.1 計測システムの開発

計測システムの構成を図3.3に示す。本研究では、シュート動作を計測するため、IMUセンサとしてSUUNTO社のMovesense[39]を使用し、記録用デバイスとしてApple社のiPhone 15[40]を採用した計測システムを構築した。Movesenseはスポーツおよび健康分野向けのセンサで、9軸IMUセンサによる加速度・角速度・地磁気の動作計測に加え、心拍センサによる心拍数や心拍間隔などの計測が可能である。本研究では、先行研究でも利用されていた加速度および角速度を、サンプリングレート100Hzで計測する。計測された3軸加速度および角速度データは、Bluetoothを通じて、iPhoneに送信され、専用アプリケーションによって記録される。このアプリケーションは、Google社が提供するマルチプラットフォームフレームワークFlutter[41]を利用して開発した。

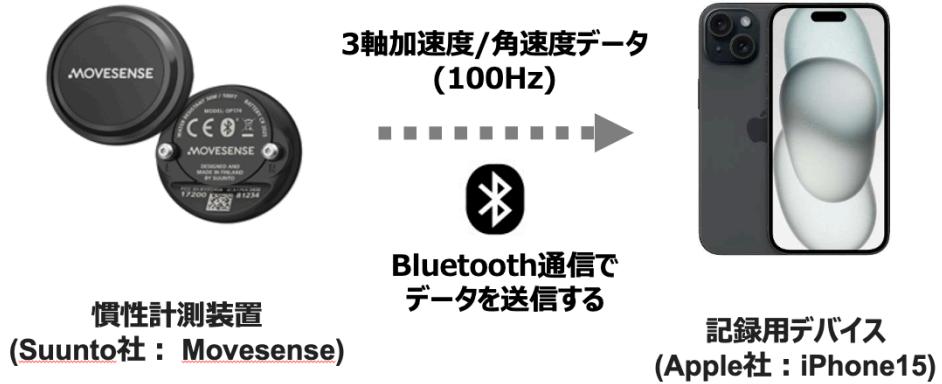


図 3.3: 計測システムの構成図

3.2.2 センサの装着位置

本研究ではIMUセンサの装着位置として、図3.4に示す胸部および両足首（外果の上）を選定した。これは、3.1.3項で設定した評価項目に基づいて、評価に必要なデータを取得することを目的としている。

まず胸部への装着は、上半身の状態を計測する上で適した位置である。背部への装着方法も検討したが、装着時に他者の補助を必要とする可能性が高く、1人での使用には不向きであると判断した。一方、胸部への装着は自身で容易に装着することができ、日常的な練習や試合での実用性が高い。次に、両足首（外果の上）の装着は、足の動作を直接的に計測する上で適した位置である。特に外側に装着することでボールの接触リスクが低く、計測の不具合やセンサの故障を防ぐことができる。また、先行研究で提案されていたスパイク内部や脛当てに装着するものに比べ、スパイクの種類やサイズに依存するところなく、専用のバンドで固定することによって、センサの安定性を確保しつつ、選手にとってストレスの少ない装着が可能となる。



図 3.4: (左) 胸部の装着イメージ、(右) 足首の装着イメージ

3.3 姿勢推定による動作評価手法

3.3.1 姿勢推定による動作評価手法の概要

本研究では、シュートフォームの評価手法として、IMUセンサによる姿勢推定を利用した手法を提案する。両足首および胸部に装着したセンサの姿勢を推定することで、選手自

身の姿勢推定を実施し、3.1.3項で設定した評価項目に基づいて、シュートのフォームを評価する。

図3.7に姿勢推定による動作評価手法の概要図を示す。まず計測したIMUセンサデータに適切な前処理を行い、センサの姿勢推定を実施する。次に、蹴り足の姿勢推定結果を用いて、シュートを構成する4つの主要ポイント（アプローチ、バックスイング、インパクト、フォロースルー）を認識する。これらのポイントを明確に認識することで、シュートフォームを3つのフェーズに分割し、各フェーズの評価項目に対応するセンサの姿勢情報を利用して選手のシュートフォームを評価する。

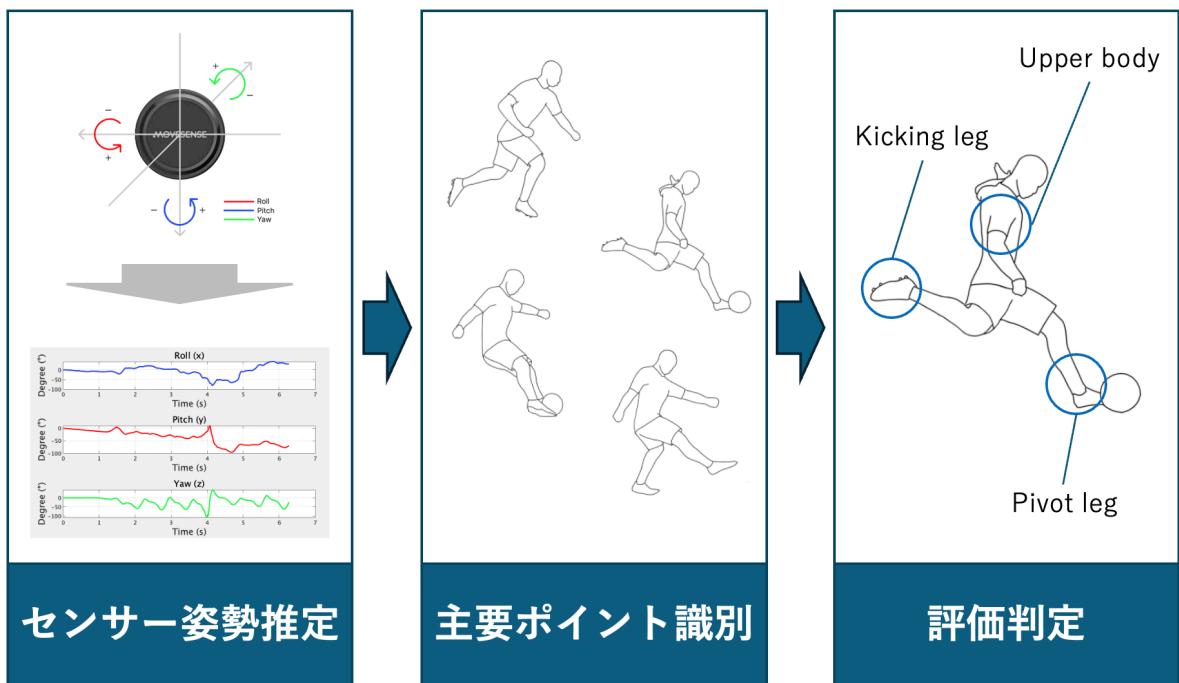


図3.5: 姿勢推定による動作評価手法の概要図

3.3.2 センサの姿勢推定処理

センサデータの姿勢推定の流れを図3.6に示す。本項では姿勢推定までの各処理について説明する。

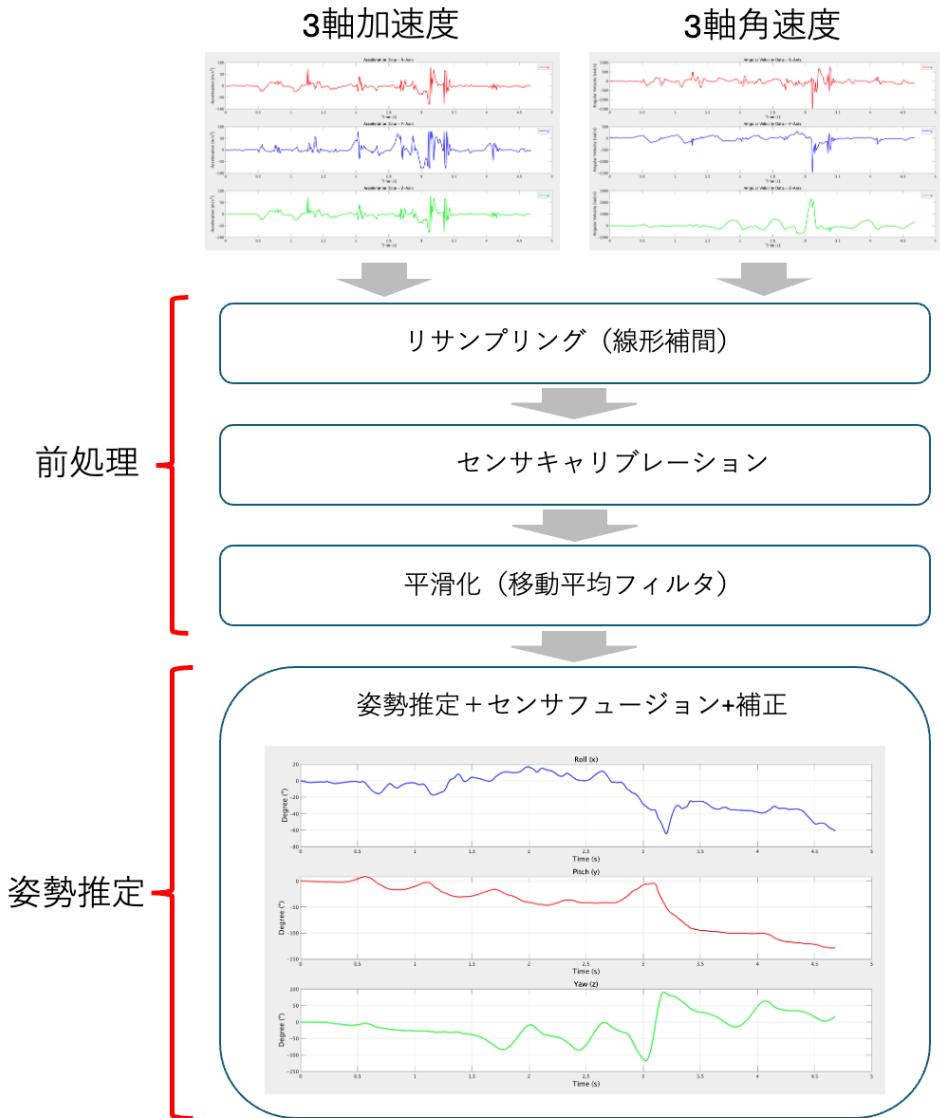


図 3.6: センサの姿勢推定の流れ

リサンプリング

本研究で利用する計測システムでは、取得される加速度および角速度データは不等間隔で記録される。データを扱いやすくするため、等間隔データに変換するリサンプリング処理を実施した。リサンプリングには、計算効率と精度のバランスを考慮し、線形補間を採用した。線形補間の式を式 3.1 に示す。この線形補間を適用することで、不等間隔データを等間隔データに変換する。

$$f(x) = f(x_1) + \frac{f(x_2) - f(x_1)}{x_2 - x_1} \cdot (x - x_1) \quad (3.1)$$

センサキャリブレーション

センサには静止状態であっても一定のオフセットが存在し、測定値が実際の値からズレる問題がみられた。これを補正するため以下の手順でバイアスキャリブレーションを実施

した。

1. 静止状態の検出

データの差分値を計算し、一定の閾値以下である区間を静止状態と見なし、該当サンプル数をカウントする。

2. 静止時の平均値計算

静止時の加速度および角速度データ（各軸）の平均値を算出する。

3. バイアス補正

算出された平均値およびセンサ装着方向を考慮した期待される値の差をバイアスとみなし、計測値を補正する。

平滑化処理

センサデータのノイズを低減する処理として、移動平均フィルタを適用する。移動平均フィルタは一定の範囲内のデータの平均を算出することで短期的な変動を抑え、滑らかなデータを得ることができる。移動平均フィルタの式を式3.2に示す。本研究では移動平均フィルタのウィンドウサイズを3に設定する。

$$S_{\text{smoothed}}(t) = \frac{1}{k} \sum_{i=1}^k S(t-i) \quad (3.2)$$

加速度センサおよび角速度センサの特性

加速度センサは重力加速度を計測することにより、静的な環境におけるセンサの絶対的な姿勢を推定することが可能である。加速度センサによる姿勢推定の利点として、長時間にわたって安定した姿勢推定が可能という点が挙げられる。しかし、動きが激しい動的環境下における精度の低さが課題である。これは、運動時に伴う重力加速度以外の加速度の影響を大きく受けるため、短期的な動作や急激な姿勢変化に対応することが難しくなるためである。

一方、角速度センサは回転角速度を測定することで姿勢を推定することが可能である。角速度センサの利点として、短期的な姿勢変化に対して高い精度で姿勢推定が可能であり、高速な動作や衝撃が伴う環境下でも比較的安定した姿勢推定ができるという点が挙げられる。しかし、角速度センサによる姿勢推定では長期的な推定には適していないという課題がある。角速度センサの姿勢推定の仕組みとして、回転速度を時間積分し、過去の姿勢に対して回転の変化量を加算していくことで姿勢を推定する。この過程で発生した微小な誤差が継続的に蓄積していく「累積誤差（ドリフト）」という現象が生じてしまう。僅かな誤差であっても、長期的な時間の経過とともに誤差が積み重なり、最終的には実際の姿勢と大きく異なる推定となってしまう。

センサフュージョンの適用

加速度センサと角速度センサはそれぞれ異なる特性を持ち、単独では姿勢推定において限界がある。本研究ではそれぞれのセンサの課題を補うセンサフュージョンの手法を適用

し精度の高い姿勢推定を実現する。代表的なセンサフュージョン手法として、相補フィルタを利用する。相補フィルタは、加速度センサと角速度センサのデータを統合し、それぞれの弱点を補完する手法である。基本原理は、ローパスフィルタで加速度データの低周波成分を、ハイパスフィルタで角速度センサの高周波成分を抽出し、これらを組み合わせることで、短期的な姿勢変化に追従しつつ、長期的な安定性を確保できる。フィルタの設計では、ローパスフィルタとハイパスフィルタのゲインの和を1とすることで、バランスを維持しつつ、位相遅れを抑えた安定した推定が可能である。相補フィルタの式を式3.3に示す。重み付け係数 α は、ジャイロセンサの信頼度を調整するパラメータであり、本研究では0.9に設定した。

$$\theta(t) = \alpha \cdot \theta_{\text{gyro}}(t) + (1 - \alpha) \cdot \theta_{\text{acc}}(t) \quad (3.3)$$

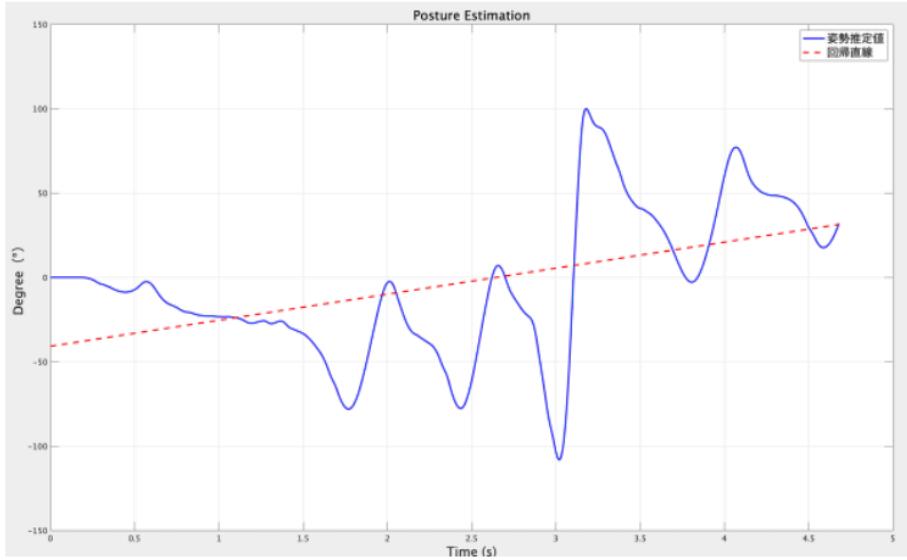
姿勢推定の補正

相補フィルタによるセンサの姿勢結果より、前処理およびセンサフュージョン手法を用いた場合でも、累積誤差の影響を完全に除去することができず、時間の経過とともに推定値が一方向に偏る傾向が見られた。この現象が発生すると、初期状態と同じ姿勢に戻った場合でも、異なる姿勢として推定される問題が生じる。本研究では、線形回帰を用いた補正手法を導入し、累積誤差による傾きを除去する処理を行う。まず、各姿勢データの傾向を線形回帰によってモデル化し、データ全体の傾きを求める。次に補正の適用に際し、時間の経過とともに補正量を大きくするため、時間を0から1に正規化した補正スケールを導入する。これにより、時系列の初期段階では補正を緩やかにし、時間の経過とともに補正を強める設計とした。最後に、線形回帰で求めた傾きと各時刻の補正スケールをもとに補正量を計算し、元のデータから差し引くことで累積誤差の影響を低減する。補正の式を式3.4に示す。

$$\theta_{\text{corrected}}(t) = \theta(t) - m_\theta \cdot t \cdot S_{\text{corr}}(t) \quad (3.4)$$

ここで、 $\theta_{\text{corrected}}(t)$ は補正後の推定角度（ロール・ピッチ・ヨーのいずれか）、 $\theta(t)$ は補正前の推定角度を表す。また、 m_θ は累積誤差の傾向を示す線形回帰によって求めた傾きであり、時間の経過に伴う推定値の偏りを示す。さらに、 t は時刻データ、 $S_{\text{corr}}(t)$ は補正スケールを表し、時間の経過とともに補正量が大きくなるよう設計されている。図3.7に補正前および補正後の姿勢推定の結果を示す。

補正前



補正後

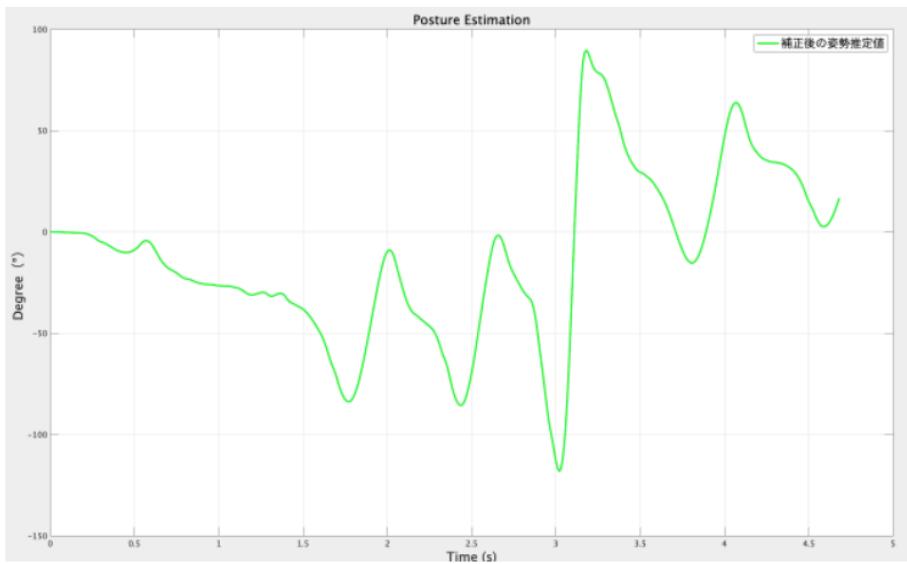


図 3.7: (左) 補正前の姿勢推定結果と回帰直線, (右) 補正後の姿勢推定結果

3.3.3 シュート動作の主要ポイントの認識

シュート動作における4つの主要ポイントを認識する手法としてセンサの姿勢推定結果を利用する。本研究では、蹴り足に装着したセンサの進行方向に対する前後の姿勢推定を利用する。この回転軸は、足の側面を通るような回転軸の回転角度を示す。

バックスイングの認識

バックスイングは蹴り足が最も高い状態である。足の側面を通るような回転軸を考慮すると、バックスイング時は特定の方向に最大の回転をすると考えられる。姿勢推定結果の最低値がバックスイングのポイントにあたる。推定結果から最低値を検出することでバックスイングを認識する。

フォロースルーの認識

フォロースルーは蹴り足が最も前方にある状態となる。足の側面を通るような回転軸を考慮すると、フォロースルー時はバックスイングとは逆方向に最大の回転をすると考えられる。姿勢推定結果より、最大値がフォロースルーのポイントにあたる。推定結果から最大値を検出することでフォロースルーを認識する。

インパクトの認識

インパクトの前後で蹴り足の傾きに着目すると、インパクト前は蹴り足がバックスイングと同様であり、インパクト後はフォロースルーと同様の傾きになる。そこでインパクトの認識は、蹴り足の姿勢推定の値の正負が切り替わるポイントであると考えられる。本研究では、バックスイングからフォロースルーにかけて、最後のマイナスであるサンプルを検出することでインパクトを認識する。

アプローチの認識

本研究で定義したアプローチのポイントは蹴り足がインパクト前に最後に地面に接地している状態であり、直立している時の足の状態と近い。姿勢推定結果より、アプローチのポイントは回転がほぼゼロに近い状態であるポイントとなる。ランニングの動作はバックスイングのように足が後ろにある状態と地面に接している状態を繰り返すことになる。足が後ろにある状態はバックスイングと同様に負の値を示し、地面に接している状態は直立状態に近いため0に近い値を示していることがわかる。本研究で定義したアプローチのポイントはインパクト前に蹴り足が最後に地面に接しているポイントである。そこでバックスイングから遡って、最初に0に近いピークを示したポイントをアプローチのポイントとして認識することができる。

以上の説明をまとめると、各ポイントはそれぞれ特徴的な姿勢推定の結果をもとに認識することができる。図??に姿勢推定の結果に基づいた各ポイントの認識の例を示す。

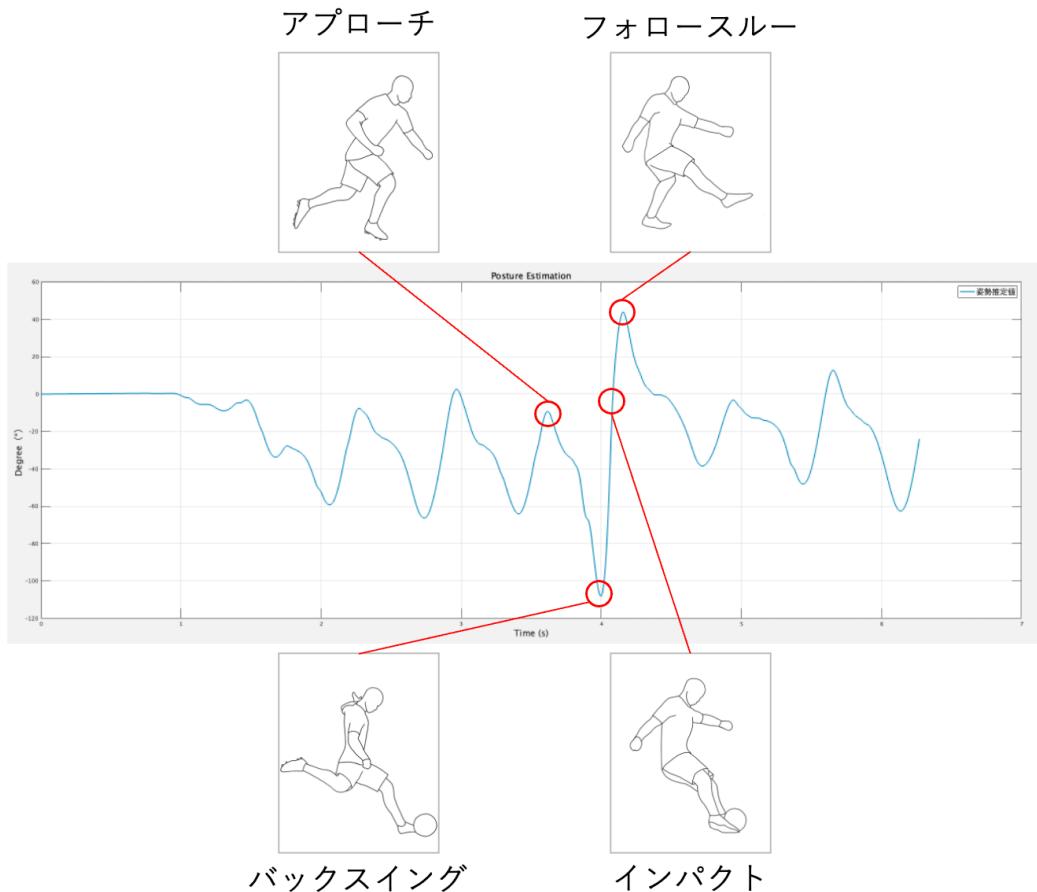


図 3.8

3.3.4 姿勢推定手法によるシュートフォーム評価

本項では、3.1.3 項で設定した評価項目をセンサの姿勢推定によって評価する方法を述べる。表 3.1 に各評価項目について、対象となるセンサと判定のタイミングを示す。

評価項目 1「バックスイング」および評価項目 2「フォロースルー」については、蹴り足に装着したセンサの姿勢推定結果を基に、バックスイング時およびフォロースルー時の角度を回帰的に求め、これらの角度をもとに評価を行う。一方で評価項目 3「軸足の傾き」および評価項目 4「上半身の傾き」については、蹴り足センサが認識した各ポイント（インパクトやフォロースルー）における、軸足および胸部のセンサの姿勢推定から姿勢状態を確認し、それぞれの良し悪しを分類的に評価する。具体的な判定方法は、評価項目 3「軸足の傾き」はインパクト時に 0° 以下の場合は「良」、 0° より上の場合は「悪」と判定し、評価項目 4「上半身の傾き」はフォロースルー時に 0° 以上の場合は「良」、 0° より未満の場合は「悪」と判定する。

表 3.1: 評価項目の判定タイミングと使用センサ

評価項目	判定タイミング	使用センサ
バックスイング	バックスイング時	蹴り足
フォロースルー	フォロースルー時	蹴り足
軸足の傾き	インパクト時	軸足
上半身の傾き	フォロースルー時	胸部

3.4 機械学習による動作評価手法

3.4.1 機械学習による動作評価手法の概要

本研究では、3.3節で紹介した姿勢推定による評価手法の比較検証として、機械学習を用いた評価手法を提案する。先行研究では、動作の分類や熟練度の判別手法として機械学習が広く活用されており、その結果、多様な動作パターンを学習し、高精度な識別が可能であることが示されている。これを踏まえ、本研究では機械学習手法をシュート動作の評価に応用できるかを検証する。

図3.9に機械学習による動作評価手法の概要図を示す。まず計測したIMUセンサデータからシュート動作をセグメントし、機械学習に利用する特徴量を抽出する。特徴量の抽出に際しては、統計データを抽出した上で、主成分分析(PCA)を用いて次元削減を実施する。最後に機械学習による分類によってシュートフォームの良し悪しを判別することで動作を評価する。

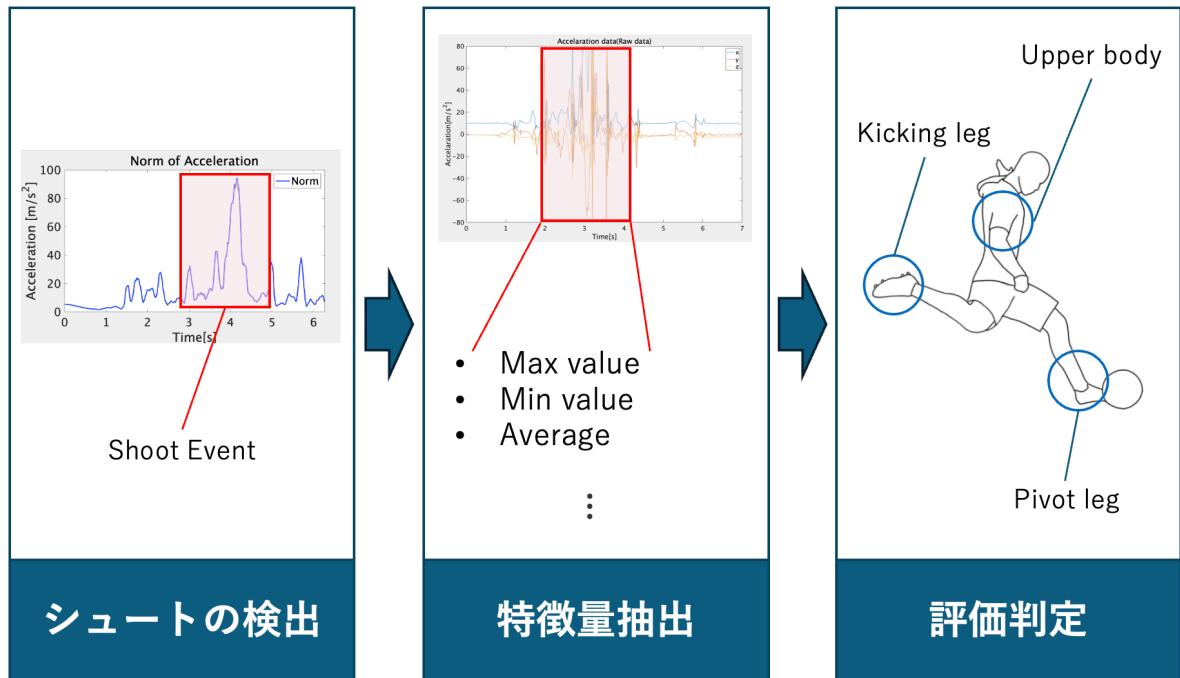


図 3.9: 機械学習による動作評価手法の概要図

3.4.2 セグメンテーション手法

計測した時系列データには、助走を行う前やキックを行った後などの評価範囲外の不要なデータが含まれる。そのため、時系列データからキックを行った部分のみを抜き出す必要がある。そこで時系列データからキックイベントを検出し、セグメントすることで抽出する。

本研究ではセグメンテーション手法としてインパクトを基準にセグメントを実施する。インパクトは蹴り足とボールが接触する瞬間の動作を指す。この動作の特徴として、蹴り足はインパクトにかけて加速し、ボールに接触した後は急激に減速する。この加速と減速の特性は加速度データにも反映され、特徴的なピークとして現れると考えられる。本研究では適切な前処理によって加速度データからインパクトを検出する。インパクト検出の流れを図 3.10 に示す。

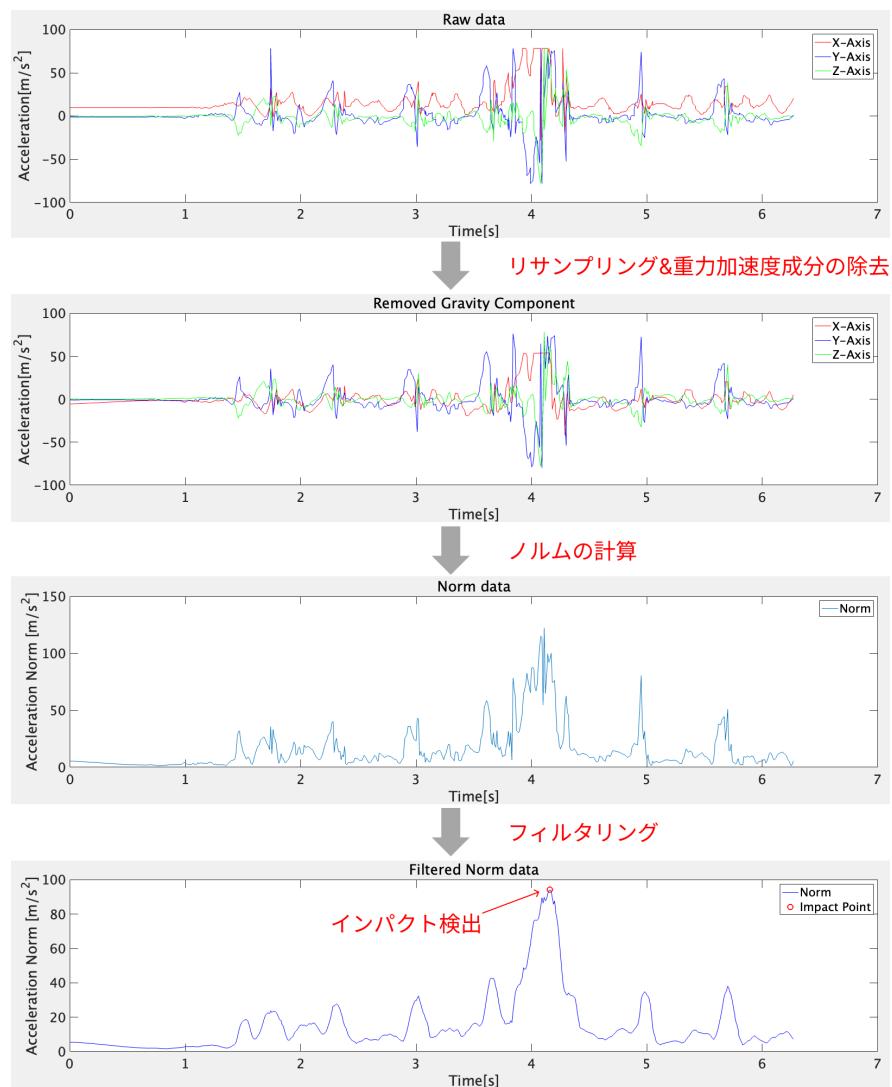


図 3.10: インパクト検出フロー

インパクト検出のための前処理

最初に加速度データから重力加速度成分を取り除き、キック動作に起因する加速度成分のみを抽出する。本研究の計測システムのセンサデータは不等間隔であるため、まず線形補間を用いて 100Hz の等間隔データにリサンプリングする。その後、高速フーリエ変換(FFT) を適用し、0.5Hz 以下の低周波成分を削除することで重力加速度成分を除去した。

次に、3 軸加速度データを統合し、運動の方向に依存しない単純な運動の強度を抽出する。これは 3 軸加速度データのノルムを計算する。ノルムは式 (3.5) によって算出する。

$$\text{norm} = \sqrt{x^2 + y^2 + z^2} \quad (3.5)$$

次に、移動平均フィルタを用いてノルムデータを平滑化し、ノイズを除去する。この処理によって加速度データの特徴的なピークを明確化する。本研究では移動平均フィルタのウィンドウサイズを 10 に設定した。平滑化したデータは式 (3.6) によって算出する。

$$S_t = \frac{1}{k} \sum_{i=1}^k \text{norm}(t - i) \quad (3.6)$$

セグメンテーション

最後に平滑化したノルムデータを基に、インパクトをノルムデータの最大値として検出する。検出したインパクトを基準とし、インパクト前 1.5 秒、インパクト後 0.5 秒の範囲をセグメントすることで抽出する。この時間範囲は、映像データをもとに算出し、シュート動作の前後の動きを十分に含むように設定した。動作の始まりから終わりまでを適切にカバーすることで、シュート動作の特徴を十分に捉えられるようにした。

3.4.3 特徴量の抽出

セグメント化されたデータを基に、機械学習の入力データとして適切な特徴量を抽出する。統計的な特徴量として、3 軸加速度および 3 軸角速度の各軸から最大値、最小値、標準偏差、平均値、中央値、範囲（最大値-最小値）、尖度、歪度の 8 種類を算出する。数値解析ソフトウェアである MATLAB[42] を用いて、合計 48 個の特徴量を抽出したデータセットを作成した。

抽出した特徴量の次元が高い場合、機械学習モデルに対して、過学習を引き起こす可能性がある。特徴量の数が増えるとモデルの複雑性が増し、学習データへの適合度が過剰に高くなり、新しいデータに対する分類精度が低下するリスクが生じる。そこで、本研究では主成分分析(PCA) を用いた次元削減を行い、データの分散を保持しつつ、不要な特徴量を削減することで、モデルの汎化性能向上を図る。具体的には、累積寄与率が 95% を保持しつつ、主成分を選択することで、情報の損失を抑えながら、次元圧縮を行う。

3.4.4 機械学習手法によるシュートフォーム評価

本研究では、シュートフォームを評価するために、回帰モデルと分類モデルを構築し、比較検証を実施する。評価項目 1 「バックスイング」と評価項目 2 「フォロースルー」に

については具体的な角度を推定するため、回帰モデル構築し、評価を行う。本研究では、線形回帰（Liner Regression）, ランダムフォレスト回帰（Random Forest Regression）, サポートベクター回帰（SVR, Support Vector Regression）, k 近傍回帰（k-Nearest Neighbors Regression, k-NNR）の4種類を用いて比較検証を実施する。評価項目3「軸足の傾き」, 評価項目4「上半身の傾き」については、フォームの良し悪しを判定するため、分類モデルを構築することで評価を行う。本研究では、ランダムフォレスト（Random Forest）, サポートベクターマシン（SVM, Support Vector Machine）, k 近傍法（k-Nearest Neighbors, k-NN）, ナイーブベイズ（Naive Bayes）の5種類の分類器を用いて比較検証を実施する。

第4章 提案手法の検証実験

4.1 データ収集実験

本節は、第3章で提案したシートフォームの評価手法の検証するために実施したデータ収集実験とその結果について説明する。

実験担当者は、臨床研究に携わる人のeラーニングサイト「ICR 臨床研究入門」にて、「研究倫理と被験者保護」および「人を対象とする医学系研究に関する倫理指針」を履修している。また、本実験は、青山学院大学理工学部ライフサイエンス委員会の「人に係る研究」に関する審査・承認を受け実施され（承認番号 H20-S10-2），被験者は実験説明を受け、実験に対する同意書による同意をもって、実験に参加頂いている。

4.1.1 実験目的

本実験の目的は、第3章で提案したシートフォームの評価手法を検証するためのデータを収集することである。現役のサッカー選手のシート動作を対象にデータを取得し、収集したデータを基に評価精度を検証することで提案手法の有効性を評価する。

4.1.2 被験者

本実験は、青山学院大学男子サッカー部に所属する現役選手18名を被験者として実施した。被験者は平均身長 171.5 ± 11.5 cm, 平均体重 63.0 ± 12 kg, 全員がサッカー歴10年以上の経験を有している。また、被験者の利き足は右利きが15名、左利きが3名であった。

4.1.3 実験方法

本実験はサッカー部が日常的に利用している人工芝グラウンドで実施した。計測には3.2節で述べた計測システムで動作を計測するとともに、カメラを被験者の後方および被験者の利き足側に設置することで、シート動作全体を撮影する。この撮影データを基に正解データとしてラベリングを実施し、提案手法の精度を検証する。

被験者にはゴールに対して正面の位置を初期位置として、静止した状態のボールに対してシート動作を開始してもらった。計測システムの操作は実験担当者が行い、各被験者に対して5回ずつ繰り返して計測した。計測中にセンサとシステムの切断が確認された場合は、追加で計測を実施した。また、被験者には特別な指示を与えず、自然な動作でシートを蹴るように求めた。本研究の実験環境を図4.1に示す。

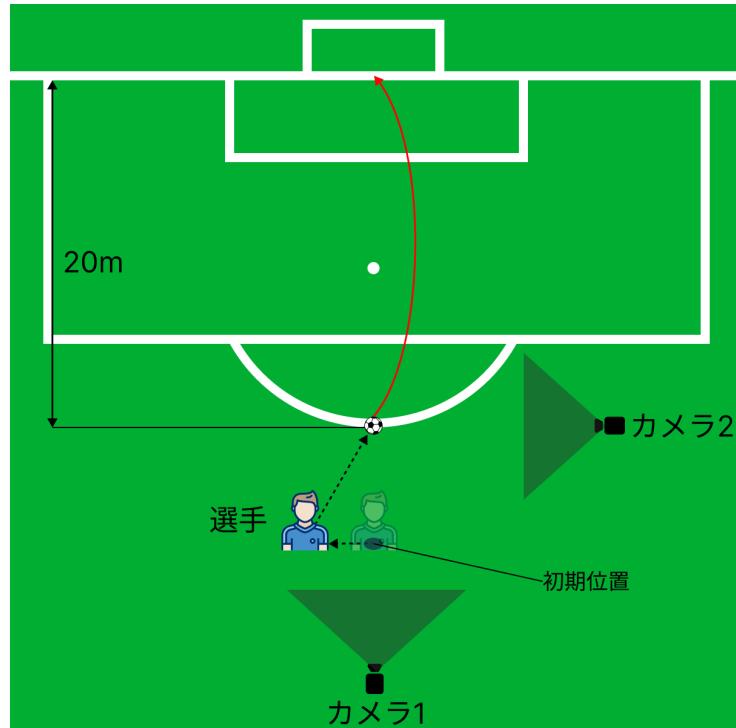


図 4.1: 実験の概要図

4.1.4 データ収集実験の結果

本実験の結果として、途中で通信が切断してしまったものも含めて、合計で 102 回の計測を実施した。計測データを確認した結果、一部のデータにおいて、図 4.2 に示すように途切れているデータが確認された。このようなデータは検証に使用できないため除外対象とした。各センサで有効と判断されたデータ数を表 4.1 に示す。

胸部および左足に装着したセンサデータは比較的安定した計測が可能であった。一方で、右足のセンサデータは通信が途切れやすい傾向が見られた。この要因として、右足が蹴り足として大きな動作を伴うため、センサに加わる動作負荷が影響した可能性が考えられる。また、センサデータを受信するスマートフォンの位置が蹴り足とは反対側となることが多かったため、通信距離が長くなつたことも要因の 1 つとなつた可能性がある。

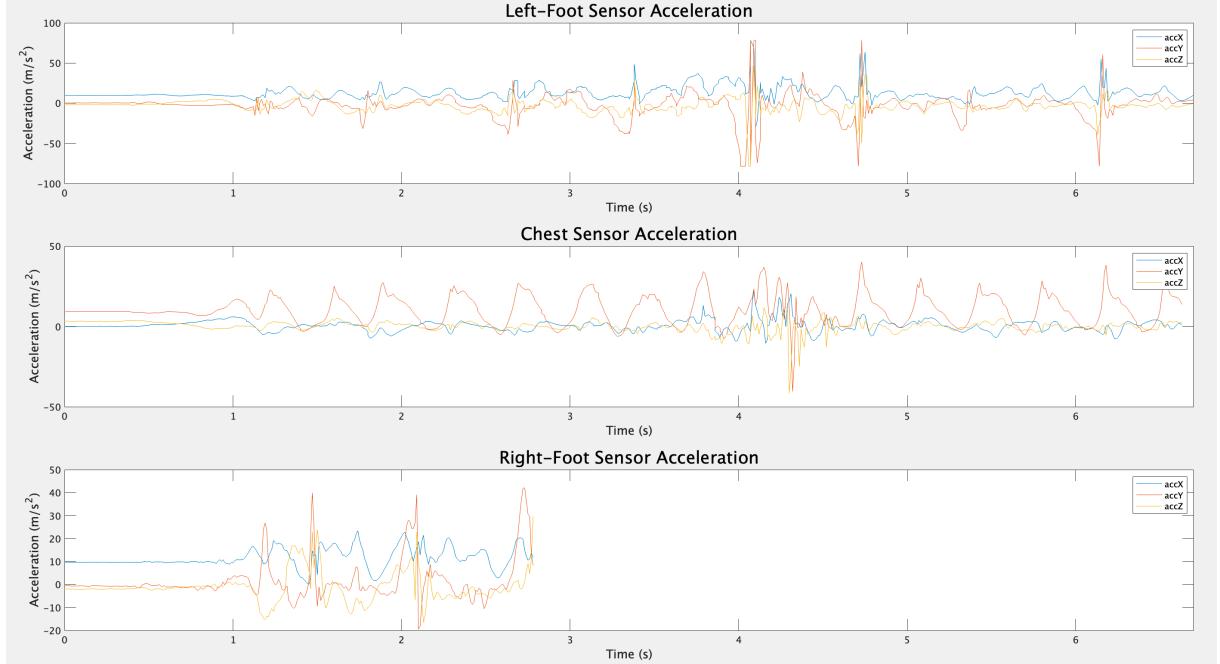


図 4.2: 除外対象としたデータ例

表 4.1: 各センサで有効と判断されたデータ数

センサ部位	有効データ数
左足	88
胸部	93
右足	93

4.2 ラベリング方法

データ収集実験で取得したデータのラベル付けには、スポーツ解析を目的とした運動解析ソフトウェアの Kinovea[43] を用いた。Kinovea は撮影した映像をインポートすることで、距離、角度、速度の計測、軌跡を描画する機能など運動の動作解析に特化した機能を利用することができる。図 4.3 に Kinovea の利用画面を示す。本研究では、設定した評価項目に関連する足の角度や上半身の傾きに関するラベリングを実施した。ラベリングの項目を表 4.2 に示す。

表 4.2: ラベリングの項目

ラベリング項目	取得データ
バックスイング	蹴り足の角度
フォロースルー	蹴り足の角度
軸足の傾き	軸足が前傾しているか / していないか
胸の姿勢	胸部が前傾しているか / していないか

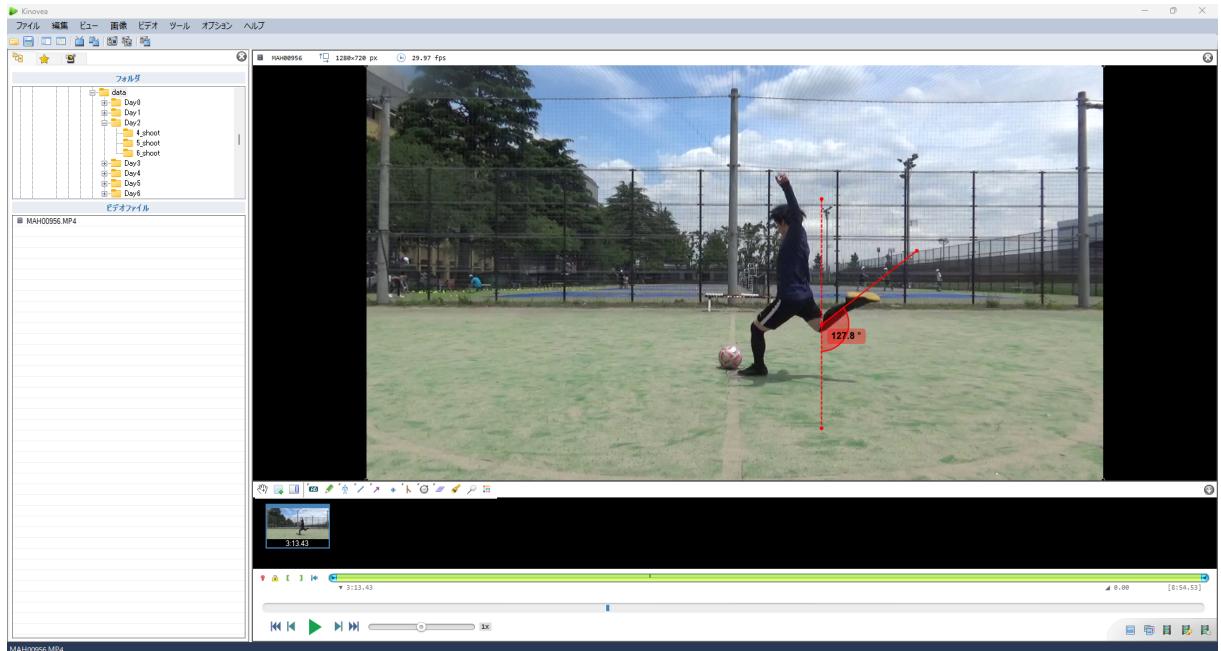


図 4.3: Kinovea ([43] から引用)

4.3 評価精度検証方法

4.3.1 姿勢推定手法の検証方法

IMU センサを用いた姿勢推定手法の精度を検証するため、数値データを用いた誤差の評価と分類ラベルの一致率による評価の 2 種類の方法を採用する。蹴り足の角度のように連続値を持つデータに対しては、推定値とラベリング結果の誤差を平均絶対誤差 (MAE) および平均絶対誤差率 (MAPE) を用いて算出し、推定精度を評価する。一方、軸足の傾きや上半身の方向のようにカテゴリ分類が必要なデータに対しては、推定値とラベルの一致率を指標として評価を行う。バックスイングとフォロースルーの検証では、蹴り足の角度に関する数値データを用い、MAE および MAPE を算出して誤差の大きさを評価する。インパクト時の軸足の傾き、上半身の傾き、上半身の方向の検証では、姿勢推定による分類結果とラベリング結果を比較し、一致率を求めて精度を評価する。これらの手法を用いて、IMU センサを活用した姿勢推定の妥当性を検証する。

IMU センサを用いた姿勢推定手法の精度を検証する方法として、回帰的な誤差評価と分類的な一致率評価の 2 種類で検証する。バックスイングやフォロースルーの蹴り足の角度に関しては、推定値とラベリング結果の誤差を平均絶対誤差 (MAE) および平均絶対誤差率 (MAPE) を用いて算出し、回帰的な手法で推定精度を評価する。一方、インパクト時の軸足の傾きやフォロースルー時の上半身の傾きについては、姿勢推定による分類結果とラベリング結果の一致率を指標とし、分類的な手法で精度を評価する。これらの手法を用いて、IMU センサを活用した姿勢推定の妥当性を検証する。

4.3.2 機械学習手法の検証方法

本研究では、3.4節で紹介した機械学習手法を用いて回帰モデルと分類モデルの両方を構築し、動作評価の精度を検証する。回帰モデルの検証は、姿勢推定手法の検証方法と同様に平均絶対誤差（MAE）および平均絶対誤差率（MAPE）を用いて算出し、推定精度を評価する。一方で分類モデルは、収集実験で得られたデータ数が限られているため、1人抜き交差検証（Leave-One-Subject-Out Cross-Validation, LOSO-CV）を適用し、適合率、再現率、F1スコアを算出し、各モデルの性能を比較する。1人抜き交差検証は、全被験者のデータから、1人分をテストデータとして除外し、残りの被験者データを用いて学習を行い、学習後に除外した被験者のデータを用いて、モデルの性能を検証する手法である。このプロセスを被験者の数だけ繰り返し、最終的に全ての被験者に対する各モデルの性能を比較する。これにより、個人差の影響を考慮しつつ、異なる被験者に対しても適用可能なモデルの精度を評価する。

第5章 提案手法の検証結果と考察

5.1 姿勢推定による動作評価手法の結果と考察

5.1.1 姿勢推定による動作評価手法の結果

評価項目1「バックスイング」および評価項目2「フォロースルー」の検証結果

IMUセンサを用いた姿勢推定による動作評価手法の精度を検証するため、評価項目1「バックスイング」および評価項目2「フォロースルー」は推定結果とラベリング結果の平均絶対誤差（MAE）および平均絶対誤差率（MAPE）を指標として検証した。検証結果を表5.1に示す。

表5.1: 評価項目1「バックスイング」および評価項目2「フォロースルー」に関する姿勢推定による評価精度

評価項目	MAE (°)	MAPE (%)
十分なバックスイング	17.5	14.0
フォロースルーの前方への動き	13.5	25.2

MAEは、推定値と正解値の絶対誤差の平均を示し、数値が小さいほど推定値が実際の値に近いことを意味する。一方、MAPEは誤差を正解値に対する割合で示し、相対的な誤差の大きさを評価する指標である。バックスイングの結果はMAE=17.5°, MAPE=14.0%, フォロースルーの結果はMAE=13.5°, MAPE=25.2%であった。これにより、バックスイングよりもフォロースルーの方が推定誤差は小さいものの、相対誤差（MAPE）は大きく、動作ごとのばらつきの影響を受けている可能性が示唆された。精度の観点では、バックスイングは一定の精度を保っているが、フォロースルーでは個人差や姿勢推定の誤差が相対的に大きくなる傾向が見られた。

評価項目3「軸足の傾き」および評価項目4「上半身の傾き」の検証結果

評価項目3「軸足の傾き」および評価項目4「上半身の傾き」は推定結果とラベリング結果の一致率を指標として検証した。検証結果を表5.2に示す。

表5.2: 軸足の傾きおよび上半身の評価精度

評価項目	一致率 (%)
インパクト時の軸足の傾き	67.0
フォロースルー時の上半身の傾き	44.0

5.1.2 姿勢推定による動作評価手法の考察

バックスイングとフォロースルーの回帰的な評価には、IMU センサによる姿勢推定の結果をそのまま利用しているため、正確な評価には一定以上の姿勢推定精度が求められる。しかし、バックスイングやフォロースルーのように大きな角度変化を伴う動作では、IMU センサの特性上、姿勢推定時の積分計算による累積誤差の影響を受けやすい。特に、バックスイングの MAPE が 14% と比較的低い値で収まっているのに対し、フォロースルーは 20% 以上と高い誤差を示しており、フォロースルーの方が動作として激しく、姿勢推定誤差が大きくなっている可能性が考えられる。また、シュート動作の流れとしてフォロースルーはバックスイングよりも後の動作であり、順番的に累積誤差が蓄積されることで、誤差がより大きくなった可能性もある。この課題に対処する方法としては、現在用いている相補フィルタ以外のセンサフェュージョン技術を導入し、姿勢推定アルゴリズムを改良することで累積誤差を低減することが考えられる。また、より多くのデータを収集し、実際の値との誤差を統計的に分析することで、誤差の傾向を明らかにし、それを考慮した補正を加えることで評価システムとしての実用性を向上させることが可能である。

軸足の傾きや上半身の傾きの分類的な評価においては、いずれも高い精度を達成することはできなかった。精度が低下した要因としては、先述のバックスイングとフォロースルーと同様に IMU センサの姿勢推定の精度自体が十分でないため、評価方法として 0° 以上を「良」、 0° 未満を「悪」のように単純な閾値設定をした場合、誤った判定結果になってしまう可能性が考えられる。この課題に対する対処法として、姿勢推定の誤差を考慮した閾値の設定を行うことが必要である。誤差がマイナス方向に生じてしまう場合は、閾値を低めに設定するなど、姿勢推定の誤差の傾向を考慮した閾値設定を導入することで、より安定した評価が可能になると考えられる。

5.2 機械学習による動作評価手法の結果と考察

5.2.1 機械学習による動作評価手法の結果

評価項目 1：バックスイング

表 5.3 に評価項目 1 「バックスイング」 の回帰モデルによる推定結果を示す。最も精度が高かったのはランダムフォレスト ($MAE = 8.6^\circ$, $MAPE = 6.8\%$) であり、最も精度が低かったのは線形回帰 ($MAE = 11.1^\circ$, $MAPE = 9.1\%$) であった。

表 5.3: 評価項目 1 「バックスイング」 の評価精度結果

Model	MAE (°)	MAPE (%)
Linear Regression	11.1	9.1
Random Forest	8.6	6.8
SVR	9.0	7.0
k-NN	8.8	7.0

評価項目 3：フォロースルー

表 5.4 に「フォロースルーの前方への動き」の回帰モデルによる推定結果を示す。最も精度が高かったのはランダムフォレスト ($MAE = 5.9^\circ$, $MAPE = 11.7\%$) であり、最も精度が低かったのは線形回帰 ($MAE = 8.2^\circ$, $MAPE = 17.4\%$) であった。

表 5.4: 評価項目 3 「フォロースルー」 の評価精度結果

Model	MAE (°)	MAPE (%)
Linear Regression	8.3	17.4
Random Forest	5.9	11.7
SVR	6.3	12.4
k-NN	6.7	13.1

評価項目 2：軸足の傾き

表 5.5 に「軸足の傾き」の機械学習による評価精度の結果を示す。ナイーブベイズが適合率 81.1%, 再現率 81.3%, F1 スコア 81.1% という最も高い精度を達成した。その他のモデルも比較的高い評価精度を示したが、サポートベクターマシンは F1 スコア 71.1% と他の手法に比べてやや低い結果となった。

表 5.5: 評価項目 2 「インパクト時の軸足の傾き」 の評価精度結果

Model	Precision[%]	Recall[%]	F1 score[%]
Random Forest	76.7	78.9	76.7
Support Vector Machine	71.1	81.8	71.1
k-Nearest Neighbor	72.2	79.5	72.2
Naive Bayes	81.1	81.3	81.1

評価項目 4：上半身の傾き

表 5.6 に「上半身の傾き」の機械学習による評価精度の結果を示す。k 近傍法 (k-Nearest Neighbor, k-NN) が適合率 87.4%, 再現率 73.6%, F1 スコア 77.4% という最も高い精度を達成した。その他のモデルも比較的高い評価精度を示したが、ナイーブベイズは F1 スコア 69.6% と他の手法に比べてやや低い結果となった。

表 5.6: 評価項目 4 「上半身の傾き」 の評価精度結果

Model	Precision[%]	Recall[%]	F1 score[%]
Random Forest	83.7	71.7	73.3
Support Vector Machine	84.1	71.4	74.3
k-Nearest Neighbor	87.4	73.6	77.4
Naive Bayes	81.5	65.0	69.6

5.2.2 機械学習による動作評価手法の考察

バックスイングおよびフォロースルーの評価精度は、どちらもランダムフォレストが最も精度が高く、線形回帰が最も低い精度となった。この結果は、バックスイングとフォロースルーの動作が単純な線形関係で表現できないことを示している。これらの動作は複数の関節が連動して行われるため、線形回帰のような単純なモデルでは適切に学習することが難しいと考えられる。一方で、ランダムフォレストのような非線形な関係を捉えられるモデルは特徴量間の相互作用を考慮できるため、高い精度を示したと考えられる。

軸足の傾きの評価精度はナイーブベイズが最も精度が高かった。ナイーブベイズの混同行列を図 5.1 に示す。「軸足の傾きが適切である」と分類すべきデータ（クラス 0）について、69 件中 66 件を正しく分類しており、高い識別精度を持つことがわかる。しかし、「軸足の傾きが適切でない」とすべきデータ（クラス 1）については、16 件中 14 件が誤分類され、適切である（クラス 0）と判定されてしまった。この誤分類の要因として、学習データの中でクラス 1 のサンプル数が少なく、モデルがクラス 0 に偏った学習をしてしまった可能性が考えられる。その結果、適切でない軸足の傾きを正しき識別する精度が低下したと考えられる。

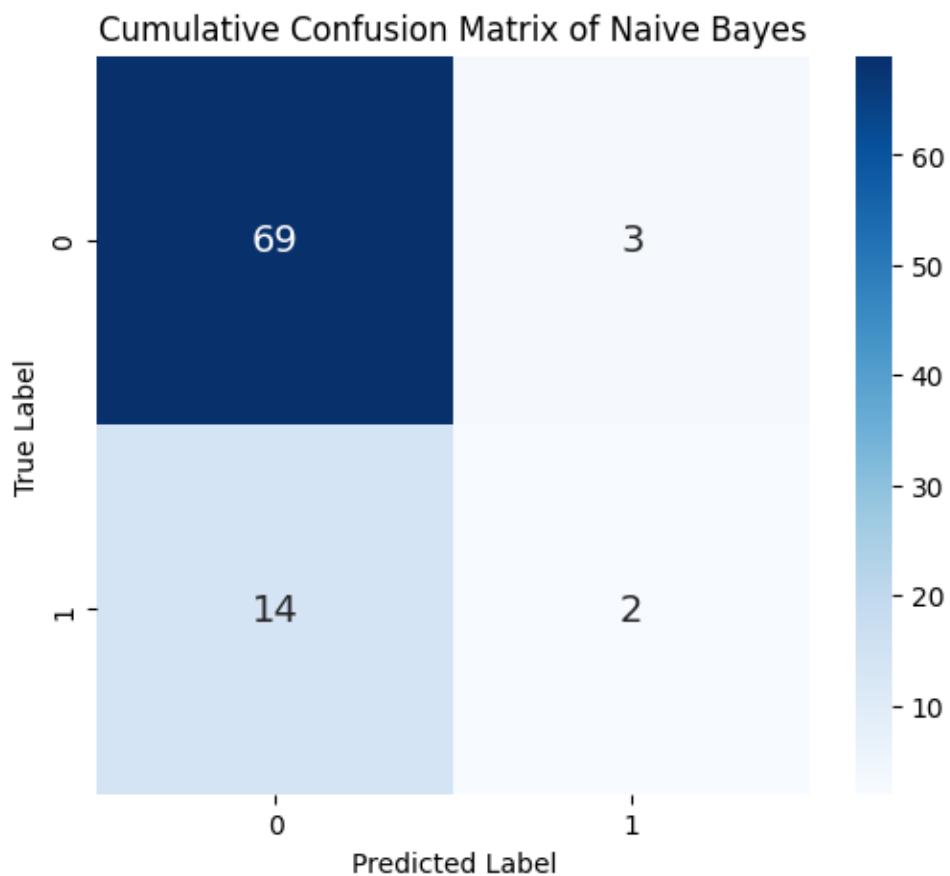


図 5.1: 「軸足の傾き」に対するナイーブベイズによる混同行列

上半身の評価精度は k 近傍法が最も精度が高かった。k 近傍法の混同行列を図 5.2 に示す。結果を確認すると、k 近傍法はクラス 0（適切な上半身の傾き）について、66 件中 57 件を正しく判定している。しかし、クラス 1（不適切な上半身の傾き）の識別精度は低く、

27件のうち16件が誤分類されており、誤判定が多数を占める結果となった。これは、クラス1のサンプル数が少なく、データサンプルに偏りがあるため、モデルがクラス0に偏った学習が考えられる。

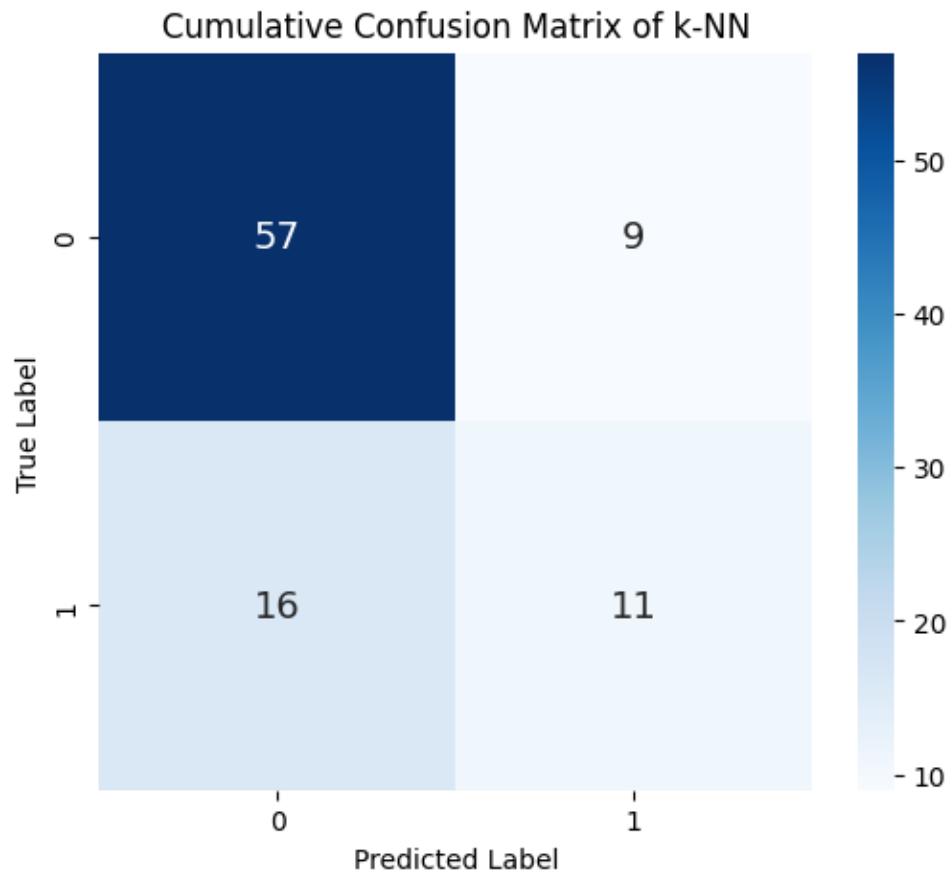


図 5.2: 「上半身の傾き」に対する k 近傍法の混同行列

第6章 結論と今後の展望

6.1 結論

本研究では、IMU センサを用いたサッカーのシュートフォーム自動評価手法を提案し、姿勢推定手法と機械学習手法を比較・検証した。姿勢推定手法はシュート動作の主要フェーズを正確に識別し、フォームの特徴を解析することに有用である一方で、一部の姿勢推定に誤差が生じた。一方、機械学習手法は時系列データから適切な特徴量を抽出し、フォームの良否を高精度で識別できることが確認された。これらの結果から、機械学習手法が評価精度の面で優れていること、姿勢推定手法が動作の分節や詳細なフォーム解析に有効であることが示された。

また、本研究では現役のサッカー選手を対象にデータ収集を行ったが、対象者の範囲が限定されていたため、モデルの汎用性向上のためにはさらなるデータ収集が必要である。さらに、姿勢推定手法の評価精度を向上させるためには、アルゴリズムの改良やセンサの装着位置の最適化が求められる。

6.2 今後の展望

本研究で提案したシュートフォーム評価手法をより実用的なシステムへと発展させるためには、いくつかの課題を解決する必要がある。まず、データ収集の多様化が挙げられる。本研究では主に現役選手を対象にデータを取得したが、より多様な選手の動作データを収集することで、モデルの一般化能力を向上させることが可能となる。特に、初心者やプロ選手を含めたデータを取得することで、技術レベルごとのフォームの違いをより詳細に分析できる。また、試合環境下でのデータ収集を行うことで、より実践的なフォーム評価の精度を検証し、実際のプレーションでの適用可能性を高めることが重要である。

次に、姿勢推定手法の精度向上が求められる。本研究では、IMU センサを用いた姿勢推定において、相補フィルタを適用することで動作の認識を行ったが、一部の姿勢推定に誤差が生じる課題があった。今後は、姿勢推定アルゴリズムの改良を行い、IMU データからの角度推定精度を向上させるとともに、センサの装着位置の最適化を進めることで、測定誤差を低減する必要がある。例えば、異なる身体部位にセンサを装着することで、より正確な姿勢情報を取得し、動作解析の精度を向上させることが考えられる。

さらに、機械学習手法の高度化も今後の重要な課題となる。本研究では、時系列データから特徴量を抽出し、フォーム評価モデルを構築したが、より精度の高い識別を実現するためには、追加の動作特徴を抽出し、学習モデルの最適化を行う必要がある。特に、LSTM や Transformer などの深層学習モデルを導入することで、時系列データの複雑なパターンを捉え、より高精度なフォーム識別が可能となると考えられる。また、従来の閾値判定手法と組み合わせることで、定量的な評価と機械学習による柔軟な識別を両立させる

ことも有効である。

本研究の成果を実際のトレーニング環境で活用するためには、リアルタイムフィードバックシステムの開発も重要である。選手が自身のフォームを即座に確認し、修正できるシステムを構築することで、より効果的な技能向上が可能となる。例えば、スマートフォンやタブレットを用いたアプリケーションを開発し、選手にリアルタイムでフォームのフィードバックを提供する仕組みを導入することが考えられる。さらに、音声や振動を用いた直感的なフィードバック機能を追加することで、選手が瞬時にフォームの改善点を認識し、修正できるようになる。

加えて、本研究で提案したフォーム評価手法をサッカーの他の動作にも応用することが期待される。シュート動作だけでなく、ドリブルやパス、ヘディングといった動作にも適用することで、総合的なスキル向上支援システムの構築が可能となる。また、コーチング支援機能を強化し、選手ごとの課題点や改善方法を具体的に提示できるシステムを開発することで、指導者の負担軽減やトレーニングの効率化にも寄与することができる。

本研究の成果をもとに、今後はIMUセンサを活用したフォーム評価技術の発展を促進し、サッカー選手の技術向上を支援する実用的なシステムの構築を目指す。

謝辞

本研究は JSPS 科研費 JP22K11998 の助成を受け、実施されました。

本研究を遂行するにあたり、青山学院大学理工学部情報テクノロジー学科ロペズ・ギヨーム教授に深く感謝申し上げます。先生のもとで研究に取り組むことができたからこそ、最後までやり遂げることができたと感じています。約4年間に渡り、研究についてご助言いただき、また多くの学びの機会を与えてくださったことに、改めて御礼申し上げます。研究補助員の大熊ちひろ様には、研究室の環境整備や TA などの事務手続きにおいて、多大なサポートをしていただきました。研究に専念できる寛容を整えてくださったことに、深く感謝いたします。本研究の実験にご協力いただいた青山学院大学サッカー部の選手の皆様、監督、コーチの皆様にも厚く御礼申し上げます。お忙しい中、実験のための環境をご提供いただき、貴重なデータ収集にご協力いただいたことに、心より感謝申し上げます。

最後に、これまで支えてくれた家族に、心から感謝いたします。常に温かく見守り、励ましてくれたおかげで、ここまで研究を続けることができました。

2025年1月31日
平井龍彦

参考文献

- [1] WorldAtlas. The most popular sports in the world. <https://www.worldatlas.com/articles/what-are-the-most-popular-sports-in-the-world.html>. (参照日 2024/7/29).
- [2] 公益財団法人 日本サッカー協会 (JFA). 日本サッカー協会 選手登録数. https://www.jfa.jp/about_jfa/organization/databox/player.html. (参照日 2024/8/1).
- [3] 公益財団法人 日本サッカー協会 (JFA). 日本サッカー協会 指導者登録数. https://www.jfa.jp/about_jfa/organization/databox/coach.html. (参照日 2024/8/1).
- [4] 公益財団法人 日本サッカー協会 (JFA). 指導者養成講習会. <https://jfa.jp/coach/official/license.html>. (参照日 2024/8/1).
- [5] イングランドサッカー協会 (TheFA) . Ratios of adults to children. <https://www.thefa.com/-/media/thefacom-new/files/rules-and-regulations/safeguarding/section-5/26072024/55-ratios-of-adults-to-children.pdf>. (参照日 2024/8/1).
- [6] INSIDE FIFA. Goal-line technology. <https://inside.fifa.com/technical/football-technology/football-technologies-and-innovations-at-the-fifa-world-cup-2022/goal-line-technology>. (参照日 2024/8/1).
- [7] SAP. Sports team management software—sap sports one. <https://www.sap.com/products/technology-platform/sports-one.html>. (参照日 2024/8/1).
- [8] Catapult. Catapult vector pro. <https://www.catapult.com/solutions/vector-pro>. (参照日 2024/8/1).
- [9] Playermaker. Playermaker 2.0. <https://www.playermaker.com/product/playermaker/>. (参照日 2024/8/1).
- [10] 青柳光璃, ギヨーム・ロペズ, 横窪安奈. Footbsense: 慣性計測装置を用いた自然環境下におけるサッカー動作の識別. 情報処理学会シンポジウムシリーズ (IPSJ Symposium Series (CD-ROM)), 第 2022 卷, pp. ROMBUNNO.8C-3. 情報処理学会, 7 2022.
- [11] Dominik Schuldhaus, Constantin Zwick, Harald Körger, Eva Dorschky, Robert Kirk, and Bjoern M. Eskofier. Inertial sensor-based approach for shot/pass classification during a soccer match. *KDD Workshop on Large-Scale Sports Analytics*, pp. 1–6, 2015.

- [12] 伊藤大晃, 後藤佑介. マルチセンサを用いたサッカー選手の動作分析システムの提案. 情報処理学会研究報告, Vol. Vol.2016-DPS-167 No.9, Vol.2016-MBL-79 No.9, Vol.2016-ITS-65 No.9, , 2016.
- [13] Maike Stoeve, Dominik Schuldhaus, Axel Gamp, Constantin Zwick, and Bjoern M. Eskofier. From the laboratory to the field: Imu-based shot and pass detection in football training and game scenarios using deep learning. *Sensors*, Vol. 21, No. 9, p. 3071, 2021.
- [14] Karin Mascher, Stefan Laller, and Manfred Wieser. Development of smart shin guards for soccer performance analysis based on mems accelerometers, machine learning, and gnss. *CEUR Workshop Proceedings*, Vol. ICL-GNSS 2021 WiP Proceedings, , 2021.
- [15] Omar AlObaid and Lakshminish Ramaswamy. A feature-based approach for identifying soccer moves using an accelerometer sensor. In *Proceedings of the 13th International Joint Conference on Biomedical Engineering Systems and Technologies (BIOSTEC 2020) - Volume 5: HEALTHINF*, pp. 34–44, Valletta, Malta, 2020. SCITEPRESS – Science and Technology Publications, Lda.
- [16] H M Sajjad Hossain, Md Abdullah Al Hafiz Khan, and Nirmalya Roy. Soccermate: A personal soccer attribute profiler using wearables. In *Proceedings of the First IEEE International Workshop on Behavioral Implications of Contextual Analytics (PerCom Workshops)*, pp. 1–6, Kona, Hawaii, USA, 2017. IEEE.
- [17] 今井友揮, 内山彰, 馬込卓弥, 東野輝夫. サッカートラッキングデータを用いた機械学習に基づくプレー認識手法の提案. 情報処理学会研究報告, Vol. Vol.2018-MBL-86 No.47, Vol.2018-UBI-57 No.47, , 2 2018.
- [18] 紅林佑亮, 清水剛士, 長谷川明生. Arduino およびセンサーを用いたスポーツ動作解析システムの試作. 情報処理学会研究報告 (IPSJ SIG Technical Report), 第 Vol.2016-IOT-34 卷, pp. 1–6. 情報処理学会, 6 2016.
- [19] 真鍋晃大, 石井直方, 福崎千穂. 慣性センサを用いたサッカー動作の解析と評価.
- [20] Katarzyna Piechota and Edyta Majorczyk. Decision-making time and neuromuscular coordination in youth and senior soccer goalkeepers. *Sensors*, Vol. 23, , 2023.
- [21] Gwyneth B. Ross, Brittany Dowling, Nikolaus F. Troje, Steven L. Fischer, and Ryan B. Graham. Classifying elite from novice athletes using simulated wearable sensor data. *Frontiers in Bioengineering and Biotechnology*, 2020.
- [22] 中村康雄, 齊藤稔, 林豊彦, 江原義弘. 熟練者・未熟練者におけるインステップキック動作解析. バイオメカニズム, Vol. 20, pp. 53–64, 2010.
- [23] 辻元典央, 内藤景, 川崎廉, 絹巻悟. サッカー未経験者におけるインステップキック動作の特徴. 福井工業大学研究紀要, Vol. 50, , 2020.
- [24] 金子和輝, 中村拓真, 矢入郁子, 平田均. Openpose を用いたサッカー熟練度の分類. 人工知能学会第 34 回全国大会論文集, 2020.

- [25] 正木直樹, 三村瑠郁, 小泉信郎, 鈴木元樹, 塩谷浩之. サッカーのパス・トラップ動作における姿勢解析のためのモーションキャプチャを用いた動作特徴量の抽出に関する検討. 情報処理学会第 85 回全国大会, 2023.
- [26] Chun Yu, Ting-Yuan Huang, and Hsi-Pin Ma. Motion analysis of football kick based on an imu sensor. *Sensors*, 2022.
- [27] Erik Wilmes, Cornelis J. de Ruiter, Bram J.C. Bastiaansen, Jasper F.J.A. van Zon, Riemer J.K. Vegter, Michel S. Brink, Edwin A. Goedhart, Koen A.P.M. Lemmink, and Geert J.P. Savelsbergh. Inertial sensor-based motion tracking in football with movement intensity quantification. *Sensors*, Vol. 20, No. 9, p. 2527, 2020.
- [28] Khaled Takizadeh, Fazlollah Bagherzadeh, Mahmoud Sheikh, Davood Hoomenian Sharif Abadi, and Hadi Veisi. The application of artificial neural network and wearable inertial sensor in kicking skill assessment. *Journal of Advanced Sport Technology*, Vol. 8, No. 1, pp. 34–45, 2023.
- [29] Ante Raa, Goran Kuvačić, Andrea De Giorgio, Maha Sellami, Luca Paolo Ardigò, Nicola Luigi Bragazzi, and Johnny Padulo. The ball kicking speed: A new, efficient performance indicator in youth soccer. *PLOS ONE*, Vol. 14, No. 5, p. e0217101, 2019.
- [30] 安達凱永, 雪竹翼, 中原匡哉. 深層学習を活用したサッカーにおける個人練習の支援技術の開発. 情報処理学会全国大会講演論文集, Vol. 85, pp. 373–374, 2023.
- [31] Joshua Marrs, Steve Barrett, Grant Abt, and Chris Towlson. Quantifying technical actions in professional soccer using foot-mounted inertial measurement units. *Science and Medicine in Football*, 2021.
- [32] Mohammed Ikram, Mohammad Dahman Alshehri, and Farookh Khadeer Hussain. Architecture of an iot-based system for football supervision (iot football). *Conference Paper*, 2015.
- [33] Håkon Kvale Stensland, Vamsidhar Reddy Gaddam, Marius Tennøe, Espen Helgedagsrud, Mikkel Næss, Henrik Kjus Alstad, Asgeir Mortensen, Ragnar Langseth, Sigurd Ljødal, Øystein Landsverk, Carsten Griwodz, and Pål Halvorsen. Bagadus: An integrated real-time system for soccer analytics. *ACM Transactions on Multimedia Computing, Communications, and Applications*, Vol. 10, No. 1s, p. Article 14 (21 pages), 2014.
- [34] 公益財団法人 日本サッカー協会 (JFA). JFA キッズ (U-8/U-10) ハンドブック. 公益財団法人 日本サッカー協会 (JFA), 3 2012. JFA キッズプログラム.
- [35] Günal Bilek and Betül Aygün. Factors associated with match result and number of goals scored and conceded in the english premier league. *Bitlis Eren University Journal of Science*, Vol. 11, No. 1, pp. 227–236, 2022.
- [36] Diego Brito Souza, Roberto López-Del Campo, Hugo Blanco-Pita, Ricardo Resta, and Juan Del Coso. A new paradigm to understand success in professional football: analysis

of match statistics in laliga for 8 complete seasons. *International Journal of Performance Analysis in Sport*, Vol. 19, No. 4, pp. 123–135.

- [37] A. Lees, T. Asai, T. B. Andersen, H. Nunome, and T. Sterzing. The biomechanics of kicking in soccer: A review. *Journal of Sports Sciences*, Vol. 28, No. 8, pp. 805–817, 2010.
- [38] 田所剛之. 東大卒キックコーチが教える 本当に正しいキックの蹴り方: 思い通りのシュートやパスを蹴られる選手になる! 日本文芸社, 東京, 4 2023. 物理学に基づくキック理論を解説した実践書.
- [39] Suunto. Movesense. <https://movesense.com/>.
- [40] Apple. iphone15. <https://www.apple.com/jp/shop/buy-iphone/iphone-15>.
- [41] google. flutter. <https://flutter.dev/>.
- [42] MathWorks. Matlab. <https://www.mathworks.com/products/matlab.html>.
- [43] Kinovea. Kinovea - video analysis software for sports. <https://www.kinovea.org/>.

質疑応答

大原 剛三 情報テクノロジー学科 教授

Q	機械学習の分類精度の指標として、なぜ Accuracy で評価をしたのか？評価する上では Precision も重要だと思います。
A	ご質問ありがとうございます。姿勢推定の評価精度の指標は Accuracy のみを算出していたため、機械学習による評価精度に関しては他の指標は省略し、accuracy を掲載しました。本論文には他の評価指標の結果も掲載しております。

浦垣 啓志郎 情報テクノロジー学科 助手

Q	センサを使った姿勢推定はいくつかあると思いますが、サッカーにおける姿勢推定の難しさは？
A	ご質問ありがとうございます。サッカーの動作は曲線的で急加速・急減速が多く、センサのノイズが大きくなりやすいという課題があります。また、長時間の利用では静止状態の姿勢推定を用いて定期的に補正するのが理想ですが、サッカーではその機会が少なく、補正が難しいと考えられます。今回は接触プレーを考慮していませんが、試合や対人練習を想定した場合、より激しい動きによってノイズが増加するため、安定した推定が難しくなる可能性があります。
Q	サッカーにおける姿勢推定の難しさに対する対処は？また、難しい結果になったことに対する考察は？
A	本研究では、ノイズ除去やセンサキャリブレーションを行い、精度の高い姿勢推定を目指しました。その結果、姿勢推定のグラフ形状は理想的でしたが、姿勢推定の具体的な値に関しては低い傾向がありました。ノイズを除去し切ることができない可能性や補正の限界による影響と考えられます。今後は、さらなる補正手法の改良や異なるセンサフェュージョン手法による精度向上を検討する必要があります。
Q	IMU をサッカー選手につけると運動の邪魔になる欠点があると思います。非侵襲的案 Vision-based なフォーム推定と提案手法とを比べた利点/欠点をもう少し強調した方が良いような気がしました。
A	カメラベースは選手の動作を妨げずに高精度な動作解析が可能ですが、設置や環境の制約が多く、コストも高くなるという欠点があります。一方、センサベースは安価で持ち運びが容易であり、環境への依存性が少なく利用できるという利点が考えられます。カメラベースとセンサベースには対照的な特徴がそれぞれありますが、アマチュア向けのシステム開発を目指す上で、センサベースの手法を選択しました。